

Параллельное программирование и суперкомпьютерный кодизайн

Смирнов А.В. asmirnov@srcc.msu.ru

Раздел 3. Многопоточное программирование в общей
памяти с использованием стандартов C++11 и выше



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ **Введение, общая память и библиотеки**
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

Виды доступа к памяти



Виды доступа к памяти




- ▶ Программирование в общей памяти позволяет практически не заботиться о задержках доступа к памяти


Процесс – это экземпляр выполняемой программы.

- ▶ Контекст:
 - регистры;
 - таблица трансляции адресов памяти;
 - ...
- ▶ Адресное пространство:
 - код программы;
 - статические данные;
 - стек;
 - разделяемая память;
 - динамическая память (куча).

Планирование процессов

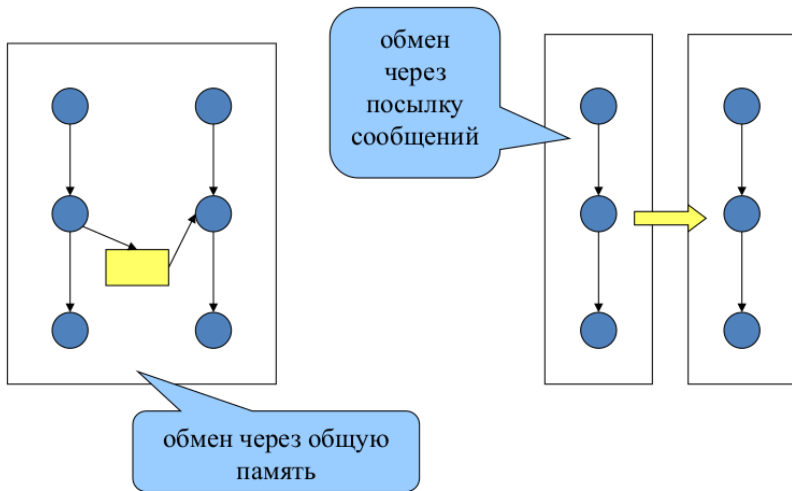


Планирование процессов



Тредами (потоки, нити, threads) называются параллельно выполняющиеся потоки управления в рамках одного процесса

- ▶ Потоки одного процесса разделяют его адресное пространство.




- ▶ Различные потоки выполняются в одном адресном пространстве.
- ▶ Различные процессы выполняются в разных адресных пространствах.
- ▶ Потоки имеют «собственный» стек и набор регистров. Глобальные данные являются общими.
- ▶ Как локальные, так и глобальные переменные процессов являются «собственными».


Два вида потоков

- ▶ Пользовательские потоки (не используются механизмы ядра)
 - Такие потоки не «видны» ОС и поэтому не могут выполняться разными ядрами, если принадлежат одному процессу
- ▶ Потоки ядра (потоки ОС) – Такие потоки могут использовать преимущества многоядерности, но их переключение требует больших ресурсов, чем пользовательских

Планирование пользовательских потоков



Планирование потоков ядра



Два вида потоков

- ▶ Пользовательские потоки (не используются механизмы ядра)
– Такие потоки не «видны» ОС и поэтому не могут выполняться разными ядрами, если принадлежат одному процессу
- ▶ Потоки ядра (потоки ОС) – Такие потоки могут использовать преимущества многоядерности, но их переключение требует больших ресурсов, чем пользовательских

Библиотеки, которые мы будем применять, используют потоки ядра

- ▶ PTHREADS – переносимая библиотека для разработки многопоточных программ
- ▶ Стандартизована POSIX Section 1003.1c
- ▶ Дает возможность получить эффективность близкую к максимально-возможной
- ▶ Опирается на системную библиотеку libstdc++ или аналогичную

- ▶ `c++11 threads` – реализация потоком в modern C++
- ▶ В posix-совместимых системах "под капотом" использует PTHREADS, на других системах может иметь альтернативную реализацию
- ▶ Мы будем использовать `c++11 threads`, PTHREADS будут приводиться только в качестве примера

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)
- ▶ C++98 – классический стандарт C++. В каком-то смысле, "C с классами"

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)
- ▶ C++98 – классический стандарт C++. В каком-то смысле, "C с классами"
- ▶ C++11, в свое время названный Modern C++, революционное обновление языка C++. Ключевые обновления - rvalue references, move семантика, lambda-функции, большое обновление стандартной библиотеки и многое другое

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)
- ▶ C++98 – классический стандарт C++. В каком-то смысле, "C с классами"
- ▶ C++11, в свое время названный Modern C++, революционное обновление языка C++. Ключевые обновления - rvalue references, move семантика, lambda-функции, большое обновление стандартной библиотеки и многое другое
- ▶ C++14 – в большей степени необходимые добавления для C++11

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)
- ▶ C++98 – классический стандарт C++. В каком-то смысле, "C с классами"
- ▶ C++11, в свое время названный Modern C++, революционное обновление языка C++. Ключевые обновления - rvalue references, move семантика, lambda-функции, большое обновление стандартной библиотеки и многое другое
- ▶ C++14 – в большей степени необходимые добавления для C++11
- ▶ C++17 – structural bindings, string_view, optional, variant, std::filesystem, constexpr if, parallel stl

- ▶ C99 – классический стандарт языка C. Является развитием стандарта C90 или ANSI C (последний совсем устарел и имеет множество неудобных ограничений)
- ▶ C++98 – классический стандарт C++. В каком-то смысле, "C с классами"
- ▶ C++11, в свое время названный Modern C++, революционное обновление языка C++. Ключевые обновления - rvalue references, move семантика, lambda-функции, большое обновление стандартной библиотеки и многое другое
- ▶ C++14 – в большей степени необходимые добавления для C++11
- ▶ C++17 – structural bindings, string_view, optional, variant, std::filesystem, constexpr if, parallel stl
- ▶ C++20, C++23, C++2c

Вопросы?

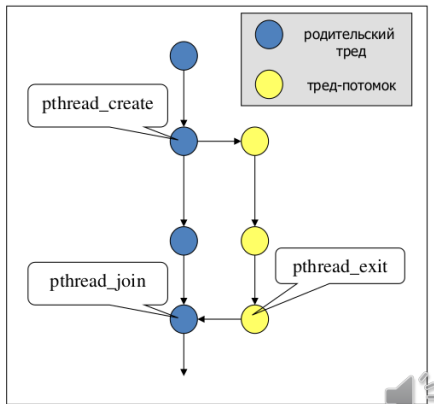


Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ **Использование потоков, передача в них параметров и возврат значений (с++11)**
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

Как это было в PTHREADS

```
int pthread_create (  
    pthread_t * outHandle,  
    pthread_attr_t *inAttribute,  
    void *(*inFunction)(void *),  
    void *inArg  
);  
  
void pthread_exit(void *inReturnValue)  
  
int pthread_join(  
    pthread_t inHandle,  
    void **outReturnValue,  
);
```



```
#include <iostream>
#include <thread>
void hello ()
{
    std::cout<<"Hello  Other  World"<<std::endl;
}
int main()
{
    std::thread t(hello);
    t.join();
}
```

```
#include <iostream>
#include <thread>
void hello ()
{
    std::cout<<"Hello  Other  World"<<std::endl;
}
int main()
{
    std::thread t(hello);
    t.join();
}
```

- ▶ Компиляция: `g++ -o name name.cpp -pthread`

Ответ на главный вопрос жизни, вселенной...



```
#include <iostream>
#include <thread>
void hello(int n)
{
    std::cout<<"The answer is "<<n<<std::endl;
}
int main()
{
    std::thread t(hello , 42);
    t.join();
}
```

Как это вообще работает?

- ▶ `std::thread t(hello);`
- ▶ `std::thread t(hello, 42);`

Как это вообще работает?

- ▶ `std::thread t(hello);`
- ▶ `std::thread t(hello, 42);`
- ▶ Здесь же разное количество параметров, и оно может быть вообще любым

Как это вообще работает?

- ▶ `std::thread t(hello);`
- ▶ `std::thread t(hello, 42);`
- ▶ Здесь же разное количество параметров, и оно может быть вообще любым

- ▶ Вариативный шаблон или шаблон с переменным числом аргументов в программировании — шаблон с заранее неизвестным числом аргументов, которые формируют один или несколько так называемых пакетов параметров.
- ▶ Вариативный шаблон позволяет использовать параметризацию типов там, где требуется оперировать произвольным количеством аргументов, каждый из которых имеет произвольный тип. Он может быть очень удобен в тех ситуациях, когда сценарий поведения шаблона может быть обобщён на неизвестное количество принимаемых данных.
- ▶ Вариативные шаблоны поддерживаются в C++ начиная со стандарта C++11.

```
template<typename T> T sum(T first) {  
    return first;  
}
```

```
template<typename T, typename ... Args>  
    T sum(T first, Args... args) {  
        return first + sum(args...);  
    }
```

```
int main()  
{  
    std::cout<<sum(20, 10, 10, 2)<<std::endl;  
}
```

- ▶ «Пустой» поток – `thread()` ;

- ▶ «Пустой» поток – `thread()` ;
- ▶ Перемещение потока – `thread(thread&& other)` ;

- ▶ «Пустой» поток – `thread()` ;
- ▶ Перемещение потока – `thread(thread&& other)` ;
- ▶ Вызов функции (функтора) в потоке – `template< class Function, class... Args > explicit thread(Function&& f, Args&&... args)` ;

- ▶ «Пустой» поток – `thread()` ;
- ▶ Перемещение потока – `thread(thread&& other)` ;
- ▶ Вызов функции (функтора) в потоке – `template< class Function, class... Args > explicit thread(Function&& f, Args&&... args)` ;
- ▶ Запрет копирования – `thread(const thread&) = delete` ;

Так можно?

- ▶ `std::thread a(help, 42);`
`std::thread b = a;`

Так можно?

- ▶ `std::thread a(help , 42);`
`std::thread b = a;`
- ▶ `std::thread a;`
`a = std::thread(help , 42);`

Так можно?

- ▶ `std::thread a(help , 42);`
`std::thread b = a;`
- ▶ `std::thread a;`
`a = std::thread(help , 42);`
- ▶ `std::thread a(help , 42);`
`std::thread b = std::move(a);`

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от =

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от =
- ▶ r-value – то, что может быть расположено справа от =

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от `=`
- ▶ r-value – то, что может быть расположено справа от `=`
- ▶ Всякий l-value это r-value, но не наоборот. Вы можете написать `int a = 2;`, но не можете написать `int a; 2 = a;`. Но при этом некоторый код может не работать для lvalue по определению

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от `=`
- ▶ r-value – то, что может быть расположено справа от `=`
- ▶ Всякий l-value это r-value, но не наоборот. Вы можете написать `int a = 2;`, но не можете написать `int a; 2 = a;`. Но при этом некоторый код может не работать для lvalue по определению
- ▶ l-value reference – ссылка на объект, которая может быть слева от знака равно, то есть ссылается на что-то реальное
`int a; int& b = a; a = 2; std::cout<<b;`

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от `=`
- ▶ r-value – то, что может быть расположено справа от `=`
- ▶ Всякий l-value это r-value, но не наоборот. Вы можете написать `int a = 2;`, но не можете написать `int a; 2 = a;`. Но при этом некоторый код может не работать для lvalue по определению
- ▶ l-value reference – ссылка на объект, которая может быть слева от знака равно, то есть ссылается на что-то реальное
`int a; int& b = a; a = 2; std::cout<<b;`
- ▶ Чем это отличается от указателя?

Что еще за `std::move`?

- ▶ l-value – то, что может быть расположено слева от `=`
- ▶ r-value – то, что может быть расположено справа от `=`
- ▶ Всякий l-value это r-value, но не наоборот. Вы можете написать `int a = 2;`, но не можете написать `int a; 2 = a;`. Но при этом некоторый код может не работать для lvalue по определению
- ▶ l-value reference – ссылка на объект, которая может быть слева от знака равно, то есть ссылается на что-то реальное
`int a; int& b = a; a = 2; std::cout<<b;`
- ▶ Чем это отличается от указателя?
`int a; int* b = &a; a = 2; std::cout<< *b;`
Обращение к ссылке (reference) не требует взятий адреса и перехода по адресу, семантика сохраняется

Что еще за std::move?

- ▶ l-value – то, что может быть расположено слева от =
- ▶ r-value – то, что может быть расположено справа от =
- ▶ Всякий l-value это r-value, но не наоборот. Вы можете написать `int a = 2;`, но не можете написать `int a; 2 = a;`. Но при этом некоторый код может не работать для lvalue по определению
- ▶ l-value reference – ссылка на объект, которая может быть слева от знака равно, то есть ссылается на что-то реальное
`int a; int& b = a; a = 2; std::cout<<b;`
- ▶ Чем это отличается от указателя?
`int a; int* b = &a; a = 2; std::cout<< *b;`
Обращение к ссылке (reference) не требует взятий адреса и перехода по адресу, семантика сохраняется r-value reference, `int&&` (с базовым классом пример бессмысленный) – ссылка, существующая только справа от знака равенства, временная или чьи ресурсы можно задействовать, инвалидируя ссылку

Что еще за `std::move`?

Функция `std::move()` — это стандартная библиотечная функция, которая конвертирует передаваемый аргумент в r-value. Мы можем передать l-value в функцию `std::move()`, и `std::move()` вернет нам ссылку r-value.

- ▶

```
std::thread a(help, 42);  
std::thread b = std::move(a);  
b.join();
```
- ▶ Попытка завершить поток `a` приведет к ошибке

```
void f(int n, std::string& s);

std::thread oops(int some_param)
{
    char buffer[1024];
    sprintf(buffer, "%i", some_param);
    std::thread t(f, 3, buffer);
    return t;
}
```

Казалось бы, что могло пойти не так?

Казалось бы, что могло пойти не так?



```
void f(int n, std::string& s);

std::thread oops(int some_param)
{
    char buffer[1024];
    sprintf(buffer, "%i", some_param);
    std::thread t(f, 3, buffer);
    return t;
}
```

Казалось бы, что могло пойти не так?

- ▶ Мы хотели передать C++ строку, а передали C строку. Конвертация произойдет в потоке, но к этому моменту локальная переменная `buffer` может уже не существовать и быть заполнена чем-то иным

Правильное решение при запуске потоков – максимально явно конвертировать параметры в нужные типы.

```
void f(int n, std::string& s);

std::thread correct(int some_param)
{
    char buffer[1024];
    sprintf(buffer, "%i", some_param);
    std::thread t(f, 3,
                  std::string(buffer)
    );
    return t;
}
```

Как передаются параметры в функции?

```
int func(int a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    int b = func(a);  
    std::cout<<a<<" | " <<b<<std::endl;  
}
```

► Что будет напечатано?

Как передаются параметры в функции?

```
int func(int a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    int b = func(a);  
    std::cout<<a<<" | " <<b<<std::endl;  
}
```

- ▶ Что будет напечатано?
- ▶ 21 0, поскольку параметры в функции передаются по значению

Вариант, пришедший из C

```
int func(int* a) {  
    *a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    int b = func(&a);  
    std::cout<<a<<" | " <<b<<std::endl;  
}
```

Вариант, который можно использовать в C++

```
int func(int& a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    int b = func(a);  
    std::cout<<a<<" | " <<b<<std::endl;  
}
```

Так не работает!

```
int func(int a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    std::thread t(func, a);  
    t.join();  
    std::cout << a << std::endl;  
}
```

А так не скомпилируется!

```
int func(int& a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    std::thread t(func, a);  
    t.join();  
    std::cout<<a<<std::endl;  
}
```

Используем `std::ref`

```
int func(int& a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    std::thread t(func, std::ref(a));  
    t.join();  
    std::cout<<a<<std::endl;  
}
```

А что будет, если сделать так?

```
int func(int a) {  
    a = 42;  
    return 0;  
}  
int main()  
{  
    int a = 21;  
    std::thread t(func, std::ref(a));  
    t.join();  
    std::cout<<a<<std::endl;  
}
```

Есть недостатки...

- ▶ Способ, описанный выше не есть в полной мере возвращение значения

Есть недостатки...

- ▶ Способ, описанный выше не есть в полной мере возвращение значения
- ▶ Недостаток состоит в том, что функция, выполняемая в потоке, ссылается на переменную, расположенную в месте вызова функции. Если функция, запустившая поток, завершила работу, подобная переменная теряет смысл, вы приходите к неопределенному поведению

Есть недостатки...

- ▶ Способ, описанный выше не есть в полной мере возвращение значения
- ▶ Недостаток состоит в том, что функция, выполняемая в потоке, ссылается на переменную, расположенную в месте вызова функции. Если функция, запустившая поток, завершила работу, подобная переменная теряет смысл, вы приходите к неопределенному поведению
- ▶ Можно делать переменную глобальной, но это усложняет задачу

Есть недостатки...

- ▶ Способ, описанный выше не есть в полной мере возвращение значения
- ▶ Недостаток состоит в том, что функция, выполняемая в потоке, ссылается на переменную, расположенную в месте вызова функции. Если функция, запустившая поток, завершила работу, подобная переменная теряет смысл, вы приходите к неопределенному поведению
- ▶ Можно делать переменную глобальной, но это усложняет задачу
- ▶ Решение: `std::future` и `std::promise`

► Решение: `std::future` и `std::promise`

Каждый объект `std::promise` связан с объектом `std::future`. Это пара классов, один из которых (`std::promise`) отвечает за установку значения, а другой (`std::future`) – за его получение.

А как получить возвращаемый результат?

```
#include <future>

void func(int& a, std::promise<int> result) {
    a = 42;
    result.set_value(1);
}

int main()
{
    int a = 21;
    std::promise<int> result;
    auto future = result.get_future();
    std::thread t(func, std::ref(a),
                  std::move(result));
    t.join();
    std::cout<<a<<" | "<<future.get()<<"\n";
}
```

Вопросы?



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ **Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)**
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

Потоки, асинхронность, а где же параллельность?

Давайте реализуем простой пример сложения двух векторов в параллельном режиме

Потоки, асинхронность, а где же параллельность?

Давайте реализуем простой пример сложения двух векторов в параллельном режиме

Этот пример исключительно технический, чтобы показать различные паттерны параллелизации, на деле он ускоряется плохо. Позже поговорим почему


```
std::random_device rd; std::mt19937 gen(rd());
std::uniform_real_distribution<double>
    uid(0., 1.);
constexpr size_t n = 32 * 1024 * 1024;
std::vector<double> a (n);
std::vector<double> b (n);
std::vector<double> c (n);
std::generate(a.begin(), a.end(),
    [&uid, &gen]() -> double {return uid(gen);}
);
std::generate(b.begin(), b.end(),
    [&uid, &gen]() -> double {return uid(gen);}
);
for (size_t i = 0; i != n; ++i) {
    c[i] = a[i] + b[i];
}
```

```
void sum(std::vector<double>& a,  
         std::vector<double>& b,  
         std::vector<double>& c,  
         size_t start, size_t end) {  
    for (size_t i = start; i != end; ++i) {  
        c[i] = a[i] + b[i];  
    }  
}
```

```
int main() {  
    // vector declaration and generation here  
    constexpr size_t tnumber = 4;  
    std::vector<std::thread> threads(tnumber);  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i] = std::thread(sum,  
            std::ref(a), std::ref(b), std::ref(c),  
            i*n/tnumber, (i+1)*n/tnumber);  
    }  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i].join();  
    }  
}
```

Примечание: задача слишком проста и упирается в скорость работы памяти. Ускорения скорей всего почти не будет

- ▶ Детально с проблемой скорости работы памяти мы познакомимся на другой лекции

Какие могут быть недостатки у такого подхода в общем случае?

Какие могут быть недостатки у такого подхода в общем случае?

- ▶ Здесь мы сами разделили задание на предположительно равные части. В общем случае они могут не быть равными

Какие могут быть недостатки у такого подхода в общем случае?

- ▶ Здесь мы сами разделили задание на предположительно равные части. В общем случае они могут не быть равными
- ▶ Более корректный вариант это позволить дочерним потокам самим брать задания из очереди заданий и выполнять их
- ▶ Попробуем реализовать и это (да еще и не одним способом)

(и, да, для сложения векторов подойдет и текущий подход, но это просто пример)

Что если завести общий счетчик?

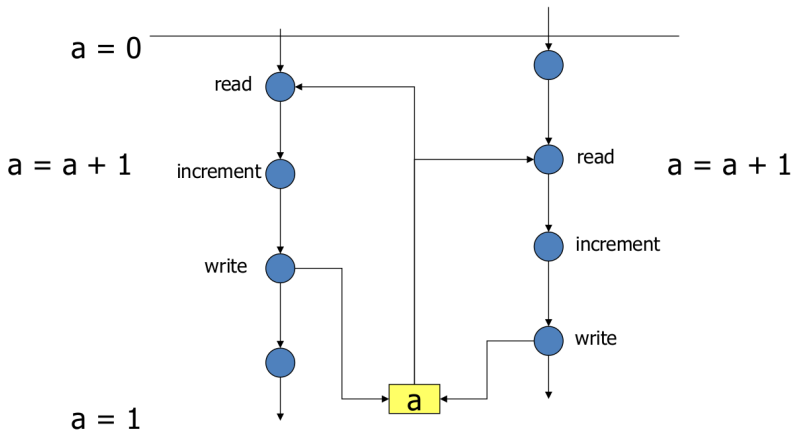
```
void sum(std::vector<double>& a,  
         std::vector<double>& b,  
         std::vector<double>& c,  
         size_t& i, size_t n) {  
    while (i < n) {  
        int j = i++;  
        c[j] = a[j] + b[j];  
    }  
}
```



```
int main() {  
    // vector declaration and generation here  
    std::vector<std::thread> threads(4);  
    size_t i = 0;  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(sum,  
            std::ref(a), std::ref(b), std::ref(c),  
            std::ref(i), n);  
    }  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i].join();  
    }  
}
```

Казалось бы, что могло пойти не так?

Казалось бы, что могло пойти не так?



- ▶ Неделимой называется операция, в момент выполнения которой состояние общих переменных не может «наблюдаться» другими тредами
- ▶ В задаче, описанной выше, нам нужно добиться того, чтобы поток не смог прочитать переменную, изменяемую другим потоком

- ▶ Атомарные переменные
- ▶ Барьерная синхронизация
- ▶ Механизм сигналов

- ▶ **Атомарные переменные**
- ▶ Барьерная синхронизация
- ▶ Механизм сигналов

- ▶ Атомарная переменная – переменная, операции изменения которой неделимы

- ▶ Атомарная переменная – переменная, операции изменения которой неделимы
- ▶ Основываются на инструкциях процессора, обеспечивающих неделимость

- ▶ Атомарная переменная – переменная, операции изменения которой неделимы
- ▶ Основываются на инструкциях процессора, обеспечивающих неделимость
- ▶ Ранее могли реализовываться при помощи специфических для компиляторов инструкций типа `__sync_fetch_and_add`

- ▶ Атомарная переменная – переменная, операции изменения которой неделимы
- ▶ Основываются на инструкциях процессора, обеспечивающих неделимость
- ▶ Ранее могли реализовываться при помощи специфических для компиляторов инструкций типа `__sync_fetch_and_add`
- ▶ Имеют полную поддержку в C++11 при помощи `std::atomic`

- ▶ Подключение `#include <atomic>`

- ▶ Подключение `#include <atomic>`
- ▶ Объявление `std::atomic<int> i` (можно использовать различные типы)

- ▶ Подключение `#include <atomic>`
- ▶ Объявление `std::atomic<int> i` (можно использовать различные типы)
- ▶ Работают все возможные операции инкремента, присваивания от обычных чисел `i++`, `i = 1`. Все эти операции являются атомарными. Аналогично, можно базовому типу присвоить атомарный.

- ▶ Подключение `#include <atomic>`
- ▶ Объявление `std::atomic<int> i` (можно использовать различные типы)
- ▶ Работают все возможные операции инкремента, присваивания от обычных чисел `i++`, `i = 1`. Все эти операции являются атомарными. Аналогично, можно базовому типу присвоить атомарный.
- ▶ Почему не работает вот такая инициализация?
`std::atomic<int> i = 0;`

- ▶ Подключение `#include <atomic>`
- ▶ Объявление `std::atomic<int> i` (можно использовать различные типы)
- ▶ Работают все возможные операции инкремента, присваивания от обычных чисел `i++`, `i = 1`. Все эти операции являются атомарными. Аналогично, можно базовому типу присвоить атомарный.
- ▶ Почему не работает вот такая инициализация?
`std::atomic<int> i = 0;`
- ▶ Можно вот так. Что это? `std::atomic<int> i = {};`

```
#include <atomic>
```

```
void sum( std::vector<double>& a,  
          std::vector<double>& b,  
          std::vector<double>& c,  
          std::atomic<size_t>& i, size_t n) {  
    while ( true ) {  
        int j = i++;  
        if ( j >= n ) {  
            break;  
        }  
        c[j] = a[j] + b[j];  
    }  
  
}
```



```
int main() {  
    // vector declaration and generation here  
    std::vector<std::thread> threads(4);  
    std::atomic<size_t> i = {};  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(sum,  
            std::ref(a), std::ref(b), std::ref(c),  
            std::ref(i), n);  
    }  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i].join();  
    }  
}
```

- ▶ Атомарные переменные
- ▶ **Барьерная синхронизация**
- ▶ Механизм сигналов

- ▶ Мьютекс – примитив синхронизации, обеспечивающий взаимное исключение исполнения критических участков кода

- ▶ Мьютекс – примитив синхронизации, обеспечивающий взаимное исключение исполнения критических участков кода
- ▶ Классический мьютекс можно представить в виде переменной, которая может находиться в двух состояниях: в заблокированном и в незаблокированном. При входе в свою критическую секцию поток вызывает функцию перевода мьютекса в заблокированное состояние, при этом поток блокируется до освобождения мьютекса, если другой поток уже владеет им. При выходе из критической секции поток вызывает функцию перевода мьютекса в незаблокированное состояние

- ▶ Мьютекс – примитив синхронизации, обеспечивающий взаимное исключение исполнения критических участков кода
- ▶ Классический мьютекс можно представить в виде переменной, которая может находиться в двух состояниях: в заблокированном и в незаблокированном. При входе в свою критическую секцию поток вызывает функцию перевода мьютекса в заблокированное состояние, при этом поток блокируется до освобождения мьютекса, если другой поток уже владеет им. При выходе из критической секции поток вызывает функцию перевода мьютекса в незаблокированное состояние
- ▶ Имеют полную поддержку в C++11 при помощи `std::mutex`

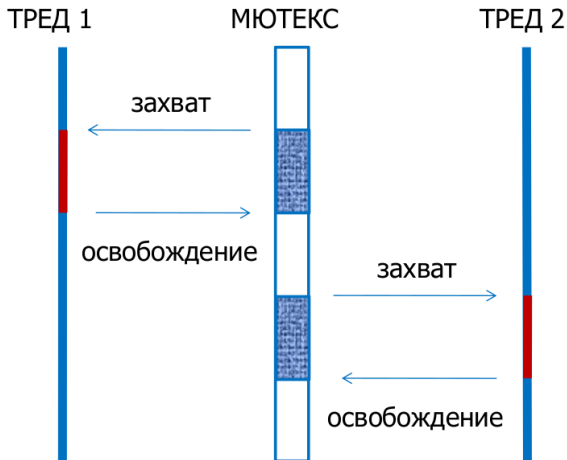
- ▶ Подключение `#include <mutex>`

- ▶ Подключение `#include <mutex>`
- ▶ Объявление `std::mutex m`

- ▶ Подключение `#include <mutex>`
- ▶ Объявление `std::mutex m`
- ▶ Захват мьютекса `m.lock()`, освобождение `m.unlock()`, попытка захвата `m.try_lock()`

- ▶ Подключение `#include <mutex>`
- ▶ Объявление `std::mutex m`
- ▶ Захват мьютекса `m.lock()`, освобождение `m.unlock()`, попытка захвата `m.try_lock()`
- ▶ Важно не забывать освобождать мьютекс, не пытаться захватить повторно той же веткой

Барьерная синхронизация (мьютексы)



```
#include <mutex>
```

```
void sum(std::vector<double>& a,  
         std::vector<double>& b,  
         std::vector<double>& c,  
         std::mutex& m, size_t& i, size_t n) {  
    while (true) {  
        m.lock();  
        int j = i++;  
        m.unlock();  
        if (j >= n) {  
            break;  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
int main() {  
    // vector declaration and generation here  
    std::vector<std::thread> threads(4);  
    size_t i = 0;  
    std::mutex m;  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(sum,  
            std::ref(a), std::ref(b), std::ref(c),  
            std::ref(m), std::ref(i), n);  
    }  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i].join();  
    }  
}
```

Варианты мьютексов

- ▶ Обычные мьютексы `std::mutex`
- ▶ Рекурсивные мьютексы `std::recursive_mutex` – позволяют потоку захватывать несколько раз, но столько же раз нужно освободить
- ▶ Разделяемые мьютексы `std::shared_mutex` (C++17) – добавляет методы разделяемой блокировки для чтения; может быть сколько угодно разделяемых блокировок одновременно, но уникальная блокировка не совмещается с разделяемой
- ▶ Дополнительно мьютексы с возможностью пытаться устанавливать блокировку ограниченное время `std::timed_mutex` и аналоги

- ▶ Один из недостатков это необходимость проследивать в коде, чтобы мьютекс обязательно был разблокирован

- ▶ Один из недостатков это необходимость проследивать в коде, чтобы мьютекс обязательно был разблокирован

Улучшение – `std::lock_guard`

- ▶ Один из недостатков это необходимость проследивать в коде, чтобы мьютекс обязательно был разблокирован

Улучшение – `std::lock_guard`

- ▶ Следует концепции RAII – resource allocation is initialization
- ▶ Освобождает мьютекс при деаллокации


```
#include <mutex>
```


```
void sum(std::vector<double>& a,
        std::vector<double>& b,
        std::vector<double>& c,
        std::mutex& m, size_t& i, size_t n) {
    while (true) {
        int j;
        { // works without these brackets...
          std::lock_guard<std::mutex> lock(m);
          j = i++;
        } // ... but worse. why?
        if (j >= n) break;
        c[j] = a[j] + b[j];
    }
}
```

```
int main() {  
    // vector declaration and generation here  
    std::vector<std::thread> threads(4);  
    size_t i = 0;  
    std::mutex m;  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(sum,  
            std::ref(a), std::ref(b), std::ref(c),  
            std::ref(m), std::ref(i), n);  
    }  
    for (size_t i = 0; i!=tnumber; ++i) {  
        threads[i].join();  
    }  
}
```

Варианты замков

- ▶ Обычные `std::lock_guard`
- ▶ Многоходовые `std::unique_lock` – как и мьютекс, поддерживают операции `lock` и `unlock`, освобождают при вызове деструктора
- ▶ Разделяемые `std::shared_lock` (C++14) – для разделяемых мьютексов
- ▶ Расширенные `std::scoped_lock` (C++17) – как обычный, но сразу можно захватить несколько мьютексов


Паттерн producer-consumer



Отступление – нужно реализовать очередь

Отступление – нужно реализовать очередь

- ▶ Разработать руками кольцевой буфер (pure C way)



Отступление – нужно реализовать очередь

- ▶ Использовать `std::vector`. Чем плохо?

Отступление – нужно реализовать очередь

- ▶ Использовать `std::vector`. Чем плохо?
- ▶ Данный тип контейнера предлагает последовательную память. Класть в конец в нормально (особенно если сделать лимит на длину), забирать из начала приводит к реаллокации

Отступление – нужно реализовать очередь

- ▶ Использовать `std::list`. Чем плохо?

Отступление – нужно реализовать очередь

- ▶ Использовать `std::list`. Чем плохо?
- ▶ `std::list` эффективно работает со списками, в которые можно класть и забирать с разных сторон, но добавление каждого нового элемента это выделение памяти

Отступление – нужно реализовать очередь

- ▶ Использовать `std::deque` (двусторонняя очередь).
- ▶ `std::deque` – наверное, лучший базовый контейнер для хранения очередь. Он выделяет память блоками на фиксированное количество элементов, используя `list` для хранения цепочки блоков, поэтому время на добавление или освобождение ограничено константой, а выделения памяти происходят существенно реже

Отступление – нужно реализовать очередь

- ▶ Использовать `std::queue` (односторонняя очередь).
- ▶ `std::queue` – контейнер более высокого уровня, реализующийся над `std::deque` (по умолчанию) или `std::list`. Предоставляет пользователю операции добавления с одной стороны и взятия с другой. Ничего не добавляет относительно `std::deque`, но концептуально лучше подходит для нашей задачи, оставляя меньше возможностей ошибиться и взять элемент не с той стороны

```
constexpr size_t n = 32 * 1024 * 1024 ;  
std::vector<double> a (n);  
std::vector<double> b (n);  
std::vector<double> c (n);  
std::mutex m;  
std::queue<size_t> q;  
bool stop = false;
```

```
void consumer() {  
    while (true) {  
        size_t j;  
        {  
            std::unique_lock<std::mutex> ul(m);  
            if (stop) break;  
            if (q.empty()) continue;  
            j = q.front();  
            q.pop();  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
void producer() {  
    for (size_t i = 0; i!=n; ++i) {  
        std::lock_guard<std::mutex> ul(m);  
        q.push(i);  
    }  
    stop = true;  
}
```

```
int main() {  
    // filling vectors here  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(consumer);  
    }  
    auto threadP = std::thread(producer);  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j].join();  
    }  
    threadP.join();  
}
```


Какая здесь проблема?

Какая здесь проблема?

- ▶ Постоянная борьба за захват мьютекса. Нужен механизм сигналов!

- ▶ Атомарные переменные
- ▶ Барьерная синхронизация
- ▶ **Механизм сигналов**

- ▶ Недостаток мьютексов – попытка захватить его может занимать ресурсы, поток не знает, когда мьютекс освободится

- ▶ Недостаток мьютексов – попытка захватить его может занимать ресурсы, поток не знает, когда мьютекс освободится
- ▶ Требуется механизм сигналов – чтобы один поток мог сообщить другому, что что-то случилось. Для этого используются так называемые переменные состояния

- ▶ Недостаток мьютексов – попытка захватить его может занимать ресурсы, поток не знает, когда мьютекс освободится
- ▶ Требуется механизм сигналов – чтобы один поток мог сообщить другому, что что-то случилось. Для этого используются так называемые переменные состояния
- ▶ Полная поддержка в C++11 через `std::condition_variable`

- ▶ Подключение: `#include condition_variable`, объявление `std::condition_variable cv`

- ▶ Подключение: `#include condition_variable`, объявление `std::condition_variable cv`
- ▶ Использование через `cv.wait(unique lock, condition);`
То есть перед ожиданием поток должен запереть мьютекс при помощи `unique lock`, после чего он ждет сигнала. `condition` – это условие, которое проверяется в момент получения сигнала на то, стоит ли потоку просыпаться или же поспать еще

- ▶ Подключение: `#include condition_variable`, объявление `std::condition_variable cv`
- ▶ Использование через `cv.wait(unique lock, condition);`
То есть перед ожиданием поток должен запереть мьютекс при помощи `unique lock`, после чего он ждет сигнала. `condition` – это условие, которое проверяется в момент получения сигнала на то, стоит ли потоку просыпаться или же поспать еще
- ▶ Другая ветка использует `cv.notify_one` или `cv.notify_all`, чтобы пробудить один или несколько ожидающих потоков

- ▶ Подключение: `#include condition_variable`, объявление `std::condition_variable cv`
- ▶ Использование через `cv.wait(unique lock, condition);`
То есть перед ожиданием поток должен запереть мьютекс при помощи `unique lock`, после чего он ждет сигнала. `condition` – это условие, которое проверяется в момент получения сигнала на то, стоит ли потоку просыпаться или же поспать еще
- ▶ Другая ветка использует `cv.notify_one` или `cv.notify_all`, чтобы пробудить один или несколько ожидающих потоков
- ▶ Попробуем написать программу (сначала плохо)

```
#include <mutex>
#include <condition_variable>
condition_variable cv;
```

```
std::condition_variable cv;  
constexpr size_t n = 32 * 1024 * 1024 ;  
std::vector<double> a (n);  
std::vector<double> b (n);  
std::vector<double> c (n);  
std::mutex m;  
std::queue<size_t> q;  
bool stop = false;
```

```
void consumer() {  
    while (true) {  
        size_t j;  
        {  
            std::unique_lock<std::mutex> ul(m);  
            cv.wait(ul);  
            if (stop) break;  
            if (q.empty()) continue;  
            j = q.front();  
            q.pop();  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
void producer() {  
    for (size_t i = 0; i!=n; ++i) {  
        std::lock_guard<std::mutex> ul(m);  
        q.push(i);  
        cv.notify_one();  
    }  
    stop = true;  
    cv.notify_all();  
}
```

```
int main() {  
    // filling vectors here  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(consumer);  
    }  
    auto threadP = std::thread(producer);  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j].join();  
    }  
    threadP.join();  
}
```

Какие же могут быть у этой программы проблемы?

Механизм сигналов



Какие же могут быть у этой программы проблемы?

- ▶ Поток может рано приступить к работе! Продюсер будит консьюмеров, когда они еще не дошли до точки, на которой будут спать. Потом будить их некому, и программа зависает

Какие же могут быть у этой программы проблемы?

- ▶ Поток может рано приступить к работе! Продюсер будит консьюмеров, когда они еще не дошли до точки, на которой будут спать. Потом будить их некому, и программа зависает
- ▶ Spurious wakeup – ситуация, когда поток просыпается, хотя ему никто не присылал сигнала! (чуть позже)

Какие же могут быть у этой программы проблемы?

- ▶ Поток может рано приступить к работе! Продюсер будит консьюмеров, когда они еще не дошли до точки, на которой будут спать. Потом будить их некому, и программа зависает
- ▶ Spurious wakeup – ситуация, когда поток просыпается, хотя ему никто не присылал сигнала! (чуть позже)

Общее правило – не использовать переменные состояния без условия!

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

- ▶ В тот момент, когда код выходит на эту строчку, мьютекс `m` должен быть захвачен (иначе неопределенное поведение)

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

- ▶ В тот момент, когда код выходит на эту строчку, мьютекс `m` должен быть захвачен (иначе неопределенное поведение)
- ▶ Программа атомарно
 - проверяет, выполняется ли условие,
 - если нет, то отпускает мьютекс и встает на ожидание сигнала
 - если да, то проскакивает дальше

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

- ▶ Программа атомарно
 - проверяет, выполняется ли условие,
 - если нет, то отпускает мьютекс и встает на ожидание сигнала
 - если да, то проскакивает дальше
- ▶ Само условие записано в виде лямбда-функции, то есть функции, которую не пришлось определять отдельно и давать ей имя. Синтаксис лямбда-функции начинается с [] (внутри скобок могут быть символы захвата, но это потом), затем () то есть список параметров функции (здесь не нужен), затем тело функции

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

- ▶ В момент пробуждения (приход сообщения) программа
 - захватывает мьютекс (эквивалентно `ul.lock()`) -
 - проверяет, выполняется ли условие,
 - если нет, то засыпает снова, освобождая mutex

Как работает переменная состояния с условием?

```
std::unique_lock<std::mutex> ul(m);  
cv.wait(ul, [](){return !start;});
```

- ▶ В момент пробуждения (приход сообщения) программа
 - захватывает мьютекс (эквивалентно `ul.lock()`) -
 - проверяет, выполняется ли условие,
 - если нет, то засыпает снова, освобождая `mutex`
- ▶ Проблема *Spurious wakeup* – поток может проснуться, хотя ему никто не присылал сигнал

```
std::condition_variable cv;  
constexpr size_t n = 32 * 1024 * 1024 ;  
std::vector<double> a (n);  
std::vector<double> b (n);  
std::vector<double> c (n);  
std::mutex m;  
std::queue<size_t> q;  
bool stop = false;
```

```
void consumer() {  
    while (true) {  
        size_t j;  
        {  
            std::unique_lock<std::mutex> ul(m);  
            cv.wait(ul, []() {  
                return ((!q.empty()) || stop);  
            });  
            if (q.empty()) break; //?? why not stop  
            j = q.front();  
            q.pop();  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
void producer() {  
    for (size_t i = 0; i!=n; ++i) {  
        std::lock_guard<std::mutex> ul(m);  
        q.push(i);  
        cv.notify_one();  
    }  
    stop = true;    // <--- there is a potential e  
    cv.notify_all();  
}
```

```
int main() {  
    // filling vectors here  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(consumer);  
    }  
    auto threadP = std::thread(producer);  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j].join();  
    }  
    threadP.join();  
}
```

Какую проблему мы не учли в этом решении?

Какую проблему мы не учли в этом решении?

- ▶ consumer проснулся
- ▶ consumer захватил mutex
- ▶ consumer проверил stop, не выполняется
- ▶ producer изменил stop
- ▶ producer послал сигнал
- ▶ consumer встал на ожидание, но больше не получит сигнал

Как это исправить?

Какую проблему мы не учли в этом решении?

- ▶ consumer проснулся
- ▶ consumer захватил mutex
- ▶ consumer проверил stop, не выполняется
- ▶ producer изменил stop
- ▶ producer послал сигнал
- ▶ consumer встал на ожидание, но больше не получит сигнал

Как это исправить?

Менять переменную под мьютексом

[https://www.modernes_cpp.com/index.php/
c-core-guidelines-be-aware-of-the-traps\
-of-condition-variables/](https://www.modernes_cpp.com/index.php/c-core-guidelines-be-aware-of-the-traps-of-condition-variables/)

```
std::condition_variable cv;  
constexpr size_t n = 32 * 1024 * 1024 ;  
std::vector<double> a (n);  
std::vector<double> b (n);  
std::vector<double> c (n);  
std::mutex m;  
std::queue<size_t> q;  
bool stop = false;
```

```
void consumer() {  
    while (true) {  
        size_t j;  
        {  
            std::unique_lock<std::mutex> ul(m);  
            cv.wait(ul, []() {  
                return ((!q.empty()) || stop);  
            });  
            if (q.empty()) break; //?? why not stop  
            j = q.front();  
            q.pop();  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
void producer() {  
    for (size_t i = 0; i!=n; ++i) {  
        std::lock_guard<std::mutex> ul(m);  
        q.push(i);  
        cv.notify_one();  
    }  
    {  
        std::lock_guard<std::mutex> ul(m);  
        stop = true;  
    }  
    cv.notify_all();  
}
```

```
int main() {  
    // filling vectors here  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(consumer);  
    }  
    auto threadP = std::thread(producer);  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j].join();  
    }  
    threadP.join();  
}
```

Какую проблему мы не учли в этом решении?

Какую проблему мы не учли в этом решении?



Какую проблему мы не учли в этом решении?

- ▶ Горшочек, не вари!
- ▶ Если производитель готовит объекты быстрее, чем их прорабатывают потребители, то очередь может расти безгранично, и может произойти неожиданное использование памяти. Это надо решать!


```
std::condition_variable cv;  
std::condition_variable cvf;  
constexpr size_t n = 32 * 1024 * 1024 ;  
constexpr size_t ql = 1024;  
std::vector<double> a (n);  
std::vector<double> b (n);  
std::vector<double> c (n);  
std::mutex m;  
std::queue<size_t> q;  
bool stop = false;
```

```
void consumer() {  
    while (true) {  
        size_t j;  
        {  
            std::unique_lock<std::mutex> ul(m);  
            cv.wait(ul, []() {  
                return ((!q.empty()) || stop);  
            });  
            if (q.empty()) break;  
            j = q.front();  
            q.pop();  
            cvf.notify_one();  
        }  
        c[j] = a[j] + b[j];  
    }  
}
```

```
void producer() {  
    for (size_t i = 0; i!=n; ++i) {  
        std::unique_lock<std::mutex> ul(m);  
        cvf.wait(ul,[](){  
            return (q.size() < ql);  
        });  
        q.push(i);  
        cv.notify_one();  
    }  
    {  
        std::lock_guard<std::mutex> ul(m);  
        stop = true;  
    }  
    cv.notify_all();  
}
```

```
int main() {  
    // filling vectors here  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j] = std::thread(consumer);  
    }  
    auto threadP = std::thread(producer);  
    for (size_t j = 0; j!=tnumber; ++j) {  
        threads[j].join();  
    }  
    threadP.join();  
}
```

- ▶ Вот только теперь этот код хорошо прорабатывает паттерн producer-consumer без лишних ожиданий, загрузки процессора или переполнения памяти. При этом мы использовали одного поставщика, но он прекрасно справляется и с многими.
- ▶ И да, это было совершенно не нужно для нашего игрушечного примера про сложение векторов.

Априорное разделение

- ▶ Мы изначально решаем, какую часть будет делать который поток
- ▶ Плюсы – простота реализации

Априорное разделение

- ▶ Мы изначально решаем, какую часть будет делать который поток
- ▶ Плюсы – простота реализации
- ▶ Почему же не ограничиться этим способом и использовать его всегда?

Априорное разделение

- ▶ Мы изначально решаем, какую часть будет делать который поток
- ▶ Плюсы – простота реализации
- ▶ Минусы – крайне ограниченная применимость ввиду невозможности балансировать нагрузку

Lock-free

- ▶ Использование атомарных переменных в качестве счетчиков
- ▶ Плюсы – простота реализации
- ▶ Минусы – ограниченная применимость, поскольку подходит только когда можно явно выделить какой-либо счетчик

Мьютексы

- ▶ Использование мьютексов для критических секций
- ▶ Плюсы – большая универсальность, чем с атомарными счетчиками, относительная простота
- ▶ Минусы – борьба многих потоков за мьютекс это большие накладные расходы. Не предоставляет полной универсальности, как следующий вариант.

Producer-consumer с сигналами

- ▶ Плюсы – универсальность
- ▶ Минусы – сложность реализации; накладные расходы для очень простых задач. Имеет смысл выбирать именно его, если требуется оптимизация, а выполнение работы поставщиком или работником существенно превышает инкремент счетчиков и операции по работе с очередью.

Потоки, асинхронность, а где же параллельность?

Мы реализовали простой пример сложения двух векторов в параллельном режиме

Этот пример исключительно технический, чтобы показать различные паттерны параллелизации, на деле он ускоряется плохо. Почему?

Мы реализовали простой пример сложения двух векторов в параллельном режиме

Этот пример исключительно технический, чтобы показать различные паттерны параллелизации, на деле он ускоряется плохо. Почему?

- ▶ Ограничены скоростью работы памяти. В цикле одна операция, два чтения и одна запись.

Мы реализовали простой пример сложения двух векторов в параллельном режиме

Этот пример исключительно технический, чтобы показать различные паттерны параллелизации, на деле он ускоряется плохо. Почему?

- ▶ Ограничены скоростью работы памяти. В цикле одна операция, два чтения и одна запись.
- ▶ В следующем разделе мы разберем пример, не упирающийся (настолько) в память. И заодно разберем принцип работы `std::async`

Вопросы?



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ **std::async и суммирование вектора (с++11)**
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

`std::async`

Если нужно более простое возвращение значения,
возможно, имеет смысл воспользоваться `std::async`

```
#include <future>
int func(int& a) {
    a = 42;
    return 1;
}
int main()
{
    int a = 21;
    std::future<int> future =
        std::async(func, std::ref(a));
    do_other_stuff();
    std::cout<<a<<" | "<<future.get()<<"\n";
}
```

Если нужно более простое возвращение значения, возможно, имеет смысл воспользоваться `std::async`

- ▶ Тот же синтаксис запуска, что и у `std::thread`
- ▶ Возвращаемое значение имеет тип `std::future`
- ▶ Метод `get` у `future` блокирует до завершения асинхронного задания

Если нужно более простое возвращение значения, возможно, имеет смысл воспользоваться `std::async`

- ▶ Тот же синтаксис запуска, что и у `std::thread`
- ▶ Возвращаемое значение имеет тип `std::future`
- ▶ Метод `get` у `future` блокирует до завершения асинхронного задания

Все не совсем так, есть нюансы

Варианты запуска std::async

- ▶ `auto result = std::async(std::launch::deferred, function, parameters);` ничего не делает до тех пор, пока не произойдет вызов `result.get()`, в тот момент выполняя функцию в текущем потоке

Варианты запуска std::async

- ▶ `auto result = std::async(std::launch::deferred, function, parameters);` ничего не делает до тех пор, пока не произойдет вызов `result.get()`, в тот момент выполняя функцию в текущем потоке
- ▶ `auto result = std::async(std::launch::async, function, parameters);` заставляет выполняться в другом потоке

Варианты запуска `std::async`

- ▶ `auto result = std::async(std::launch::deferred, function, parameters);` ничего не делает до тех пор, пока не произойдет вызов `result.get()`, в тот момент выполняя функцию в текущем потоке
- ▶ `auto result = std::async(std::launch::async, function, parameters);` заставляет выполняться в другом потоке
- ▶ `auto result = std::async(std::launch::async | std::launch::deferred, function, parameters);` оставляет решение за библиотекой (поведение по умолчанию)

Если вызвать `std::async` без присвоения результата куда-либо, код будет заблокирован в этой точке до момента завершения вычисления функции. Почему?

Если вызвать `std::async` без присвоения результата куда-либо, код будет заблокирован в этой точке до момента завершения вычисления функции. Почему?

- ▶ Время существования задания на выполнение функции в `std::async` привязано к времени возвращенного им `std::future`. Если результат никуда не присвоен, то создается временный объект, у него вызывается деструктор, и система должна дождаться выполнения функции.

std::thread

- ▶ + Больше контроля за выполнением потоков («ручное управление»)
- ▶ - Сложный доступ к результату выполнения
- ▶ - Проблемы балансировки и перегрузки системы (oversubscription)

std::thread

- ▶ + Больше контроля за выполнением потоков («ручное управление»)
- ▶ - Сложный доступ к результату выполнения
- ▶ - Проблемы балансировки и перегрузки системы (oversubscription)

std::async

- ▶ + больше свободы системе в плане балансировки нагрузки (система решает запускать новый поток или нет)
- ▶ + легкий доступ к результату через std::future
- ▶ - отсутствие низкоуровневого контроля

std::thread

- ▶ + Больше контроля за выполнением потоков («ручное управление»)
- ▶ - Сложный доступ к результату выполнения
- ▶ - Проблемы балансировки и перегрузки системы (oversubscription)

std::async

- ▶ + больше свободы системе в плане балансировки нагрузки (система решает запускать новый поток или нет)
- ▶ + легкий доступ к результату через std::future
- ▶ - отсутствие низкоуровневого контроля

еще есть std::packaged_task...

Thread oversubscription

Oversubscription - ситуация, когда число потоков превышает число физически доступных ядер.

Oversubscription - ситуация, когда число потоков превышает число физически доступных ядер.

- ▶ + Небольшое превышение может позитивно сказаться на производительности: когда один поток ожидает на операциях с памятью, другой выполняет вычисления. Это позволяет задействовать внутрипроцессорный параллелизм и, тем самым, ускорить выполнение программы.

Oversubscription - ситуация, когда число потоков превышает число физически доступных ядер.

- ▶ + Небольшое превышение может позитивно сказаться на производительности: когда один поток ожидает на операциях с памятью, другой выполняет вычисления. Это позволяет задействовать внутрипроцессорный параллелизм и, тем самым, ускорить выполнение программы.
- ▶ - Переключение контекста потока приводит к непродуктивным накладным расходам. Поэтому если число потоков намного превышает число ядер, то переключение контекста может существенно снизить производительность программы.

Oversubscription - ситуация, когда число потоков превышает число физически доступных ядер.

- ▶ + Небольшое превышение может позитивно сказаться на производительности: когда один поток ожидает на операциях с памятью, другой выполняет вычисления. Это позволяет задействовать внутрипроцессорный параллелизм и, тем самым, ускорить выполнение программы.
- ▶ - Разные потоки, как правило, работают с разными данными. Поэтому при переключении ядра между потоками из кэш-памяти вытесняются данные, с которыми работал поток. Когда поток опять ставится на выполнение, увеличивается время на доступ к данным, т.к. требуется их загрузка в кэш из основной памяти.


```
double sum_vector(std::vector<double>& a,  
    size_t start, size_t end) {  
    double res = 0.;  
    for (size_t i = start; i!=end; i++) {  
        res = res + a[i];  
    }  
    return res;  
}
```

```
int main() {  
    constexpr size_t n = 256 * 1024 * 1024;  
    std::vector<double> a(n);  
    // fill with random here  
    auto start =  
        std::chrono::steady_clock::now();  
    double res = sum_vector(a, 0, n);  
    auto end =  
        std::chrono::steady_clock::now();  
    auto diff = end - start;  
    int time = std::chrono::duration_cast<  
        std::chrono::milliseconds>(diff).count();  
    std::cout << time << " ms" << std::endl;  
}
```

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H,
4 cores

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H, 4 cores)

- ▶ Последовательное выполнение – 222 ms

```
double sum_vector(std::vector<double>& a,  
    size_t start, size_t end) {  
    double res = 0.;  
    for (size_t i = start; i!=end; i++) {  
        res = res + a[i];  
    }  
    return res;  
}
```

Теперь реализация с `async` (только содержимое `main` внутри замера времени)

```
double res = 0.;
size_t block = n/NTHREADS;
std::future<double> f[NTHREADS];
for (int i = 0; i!=NTHREADS; ++i) {
    f[i] = std::async(
        std::launch::async ,
        sum_vector , std::ref(a) ,
        i*block , (i+1)*block );
}
for (int i = 0; i!=NTHREADS; ++i) {
    res += f[i].get();
}
```

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H, 4 cores)

- ▶ Последовательное выполнение – 222 ms
- ▶ 2 потока – 140 ms

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H, 4 cores)

- ▶ Последовательное выполнение – 222 ms
- ▶ 2 потока – 140 ms
- ▶ 4 потока – 103 ms

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H, 4 cores)

- ▶ Последовательное выполнение – 222 ms
- ▶ 2 потока – 140 ms
- ▶ 4 потока – 103 ms
- ▶ 8 потоков – 87 ms (oversubscription)

Замеряем время (компилируем с -O3, AMD Ryzen 7 3750H, 4 cores)

- ▶ Последовательное выполнение – 222 ms
- ▶ 2 потока – 140 ms
- ▶ 4 потока – 103 ms
- ▶ 8 потоков – 87 ms (oversubscription)
- ▶ В режиме `std::launch::deferred` ускорения не происходит. В режиме выбора за библиотекой на моем компьютере результаты совпали с явно указанным `std::launch::async`

Делаем программу, собирающуюся в разных режимах

```
#ifndef NTHREADS
#define NTHREADS 4
#endif

int main() {
    .....
#ifdef ASYNC
    double res = 0.;
    size_t block = n/NTHREADS;
    std::future<double> f[NTHREADS];
    for (int i = 0; i!=NTHREADS; ++i) {
```

Делаем программу, собирающуюся в разных режимах

```
f[i] = std::async(  
    std::launch::async ,  
    sum_vector , std::ref(a) ,  
    i*block , (i+1)*block );  
}  
for (int i = 0; i!=NTHREADS; ++i) {  
    res += f[i].get();  
}  
#else  
    double res = sum_vector(a, 0, n);  
#endif  
.....  
}
```

Делаем программу, собирающуюся в разных режимах

- ▶ Программу теперь можно собирать через

```
g++ -DASYNC -DNTHREADS=8 program.cpp  
-o program -pthread
```

Вопросы?



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ **Make и Makefile. Основы использования git.**
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

- ▶ Утилита `make` обычно устанавливается через менеджеры пакетов, например, `apt-get install make`. Чтобы запустить `make` в командной строке, нужно в той же папке иметь файл, так и называющийся, `Makefile`

- ▶ Утилита `make` обычно устанавливается через менеджеры пакетов, например, `apt-get install make`. Чтобы запустить `make` в командной строке, нужно в той же папке иметь файл, так и называющийся, `Makefile`

- Утилита make обычно устанавливается через менеджеры пакетов, например, `apt-get install make`. Чтобы запустить make в командной строке, нужно в той же папке иметь файл, так и называющийся, Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

- Утилита make обычно устанавливается через менеджеры пакетов, например, `apt-get install make`. Чтобы запустить make в командной строке, нужно в той же папке иметь файл, так и называющийся, `Makefile`

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Обычно вы бы собрали этот код через

`g++`

`-o hellomake hellomake.cpp hellofunc.cpp -I.`

Использование make и Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Makefile. Вариант 1:

```
hellomake: hellomake.cpp hellofunc.cpp
    g++ -o hellomake hellomake.cpp hellofunc.cpp -I.
```

(внимание: отступ перед g++ это табуляция!)

Что важно - повторные вызов make приведет к пересборке только если изменился один из указанных файлов

Использование make и Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Makefile. Вариант 2, отделяем компиляцию и линковку:

CC=g++

CFLAGS=-I.

hellomake: hellomake.o hellofunc.o

 \${CC} -o hellomake hellomake.o hellofunc.o

hellomake.o: hellomake.cpp

 \${CC} -c -o hellomake.o hellomake.cpp \${CFLAGS}

hellofunc.o: hellofunc.cpp

 \${CC} -c -o hellofunc.o hellofunc.cpp \${CFLAGS}

Использование make и Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Makefile. Вариант 3, упрощаем код ссылаясь на цель и зависимость:

CC=g++

CFLAGS=-I.

OBJ = hellomake.o hellofunc.o

hellomake: \${OBJ}

 \${CC} -o \$@ \$^

hellomake.o: hellomake.cpp

 \${CC} -c -o \$@ \$^ \${CFLAGS}

hellofunc.o: hellofunc.cpp

 \${CC} -c -o \$@ \$^ \${CFLAGS}

Использование make и Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Makefile. Вариант 4, убираем повторяющиеся строки

CC=g++

CFLAGS=-I .

OBJ = hellomake.o hellofunc.o

```
hellomake: ${OBJ}
    ${CC} -o $@ $^
```

```
%.o: %.cpp
    ${CC} -c -o $@ $^ ${CFLAGS}
```

Использование make и Makefile

hellomake.cpp	hellofunc.cpp	hellofunc.h
<pre>#include <hellofunc.h> int main() { // call a function in another file myPrintHelloMake(); return(0); }</pre>	<pre>#include <iostream> #include <hellofunc.h> void myPrintHelloMake(void) { std::cout<<"Hello makefiles!\n"; return; }</pre>	<pre>/* example include file */ void myPrintHelloMake(void);</pre>

Makefile. Вариант 5, добавляем зависимость от заголовочного файла

CC=g++

CFLAGS=-I.

DEPS = hellofunc.h

OBJ = hellomake.o hellofunc.o

```
hellomake: ${OBJ}
    ${CC} -o $@ $^
```

```
%.o: %.cpp ${DEPS}
    ${CC} -c -o $@ $< ${CFLAGS}
```


Makefile. Вариант 6, добавляем команду для очистки

```
CC=g++
CFLAGS=-I.
DEPS = hellofunc.h
OBJ = hellomake.o hellofunc.o
```

```
hellomake: ${OBJ}
    ${CC} -o $@ $^
```

```
%.o: %.cpp ${DEPS}
    ${CC} -c -o $@ $< ${CFLAGS}
```

```
.PHONY: clean
```

```
clean:
    rm -f *.o hellomake
```

- ▶ Git - это консольная утилита, для отслеживания и ведения истории изменения файлов, в вашем проекте

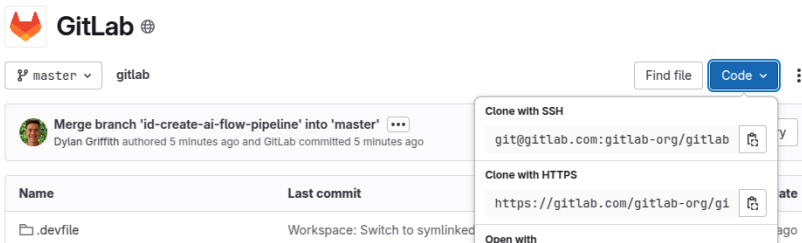
- ▶ Git - это консольная утилита, для отслеживания и ведения истории изменения файлов, в вашем проекте
- ▶ Не стоит путать git и github. Первое это утилита, с которой можно работать вообще локально на вашем компьютере. Второе - один из возможных серверов для ведения совместной разработки и для того, чтобы делиться кодом (хоть и самый известный).

- ▶ Git - это консольная утилита, для отслеживания и ведения истории изменения файлов, в вашем проекте
- ▶ Не стоит путать git и github. Первое это утилита, с которой можно работать вообще локально на вашем компьютере. Второе - один из возможных серверов для ведения совместной разработки и для того, чтобы делиться кодом (хоть и самый известный).
- ▶ Известные варианты git серверов это <https://github.com/>, <https://bitbucket.org/>, <https://gitlab.com/>. Продвигаются различные российские, например, <https://gitverse.ru/> от сбербанка.

- ▶ Git - это консольная утилита, для отслеживания и ведения истории изменения файлов, в вашем проекте
- ▶ Не стоит путать git и github. Первое это утилита, с которой можно работать вообще локально на вашем компьютере. Второе - один из возможных серверов для ведения совместной разработки и для того, чтобы делиться кодом (хоть и самый известный).
- ▶ Известные варианты git серверов это <https://github.com/>, <https://bitbucket.org/>, <https://gitlab.com/>. Продвигаются различные российские, например, <https://gitverse.ru/> от Сбербанка.
- ▶ Также gitlab интересен тем, что они предлагают код git сервера, который можно развернуть локально, например, такой развернут у нас в НИВЦ: <https://gitlab.srcc.msu.ru/>

- ▶ Установка под debian-based: `sudo apt install git`, про остальное смотрите под свою систему. Итогом является то, что вы получаете возможность в командной строке давать команды, начинающиеся с `git`

- ▶ Установка под debian-based: `sudo apt install git`, про остальное смотрите под свою систему. Итогом является то, что вы получаете возможность в командной строке давать команды, начинающиеся с `git`
- ▶ Хотя с `git` можно работать полностью локально, начать лучше с клонирования какого-то репозитория. Например, с `gitlab` вы можете клонировать код самого `gitlab` по адресу <https://gitlab.com/gitlab-org/gitlab>



The screenshot shows the GitLab web interface. At the top left is the GitLab logo and name. Below it, there's a dropdown menu for branches, currently showing 'master'. To the right is a search bar labeled 'Find file' and a 'Code' button. Below the search bar, there's a merge commit message: 'Merge branch 'id-create-ai-flow-pipeline' into 'master'' by Dylan Griffith, committed 5 minutes ago. Below this is a table with columns 'Name' and 'Last commit'. The table has one row: '.devfile' with the commit message 'Workspace: Switch to symlinked'. On the right side, a dropdown menu is open, showing options to 'Clone with SSH' (using `git@gitlab.com:gitlab-org/gitlab`) and 'Clone with HTTPS' (using `https://gitlab.com/gitlab-org/gi`).

GitLab

master ▾ gitlab

Find file Code ▾

Merge branch 'id-create-ai-flow-pipeline' into 'master' ...
Dylan Griffith authored 5 minutes ago and GitLab committed 5 minutes ago

Name	Last commit
.devfile	Workspace: Switch to symlinked

Clone with SSH
git@gitlab.com:gitlab-org/gitlab

Clone with HTTPS
https://gitlab.com/gitlab-org/gi

Open with

- ▶ На git-хостингах предлагается выбор, клонировать по ssh или https. Для скачивания чего-то публичного проще использовать https, для регулярной разработки рекомендуется ssh, чтобы единожды залить на сервер свой публичный ключ и не вводить пароль при каждой команде. Итак, к адресу из команды клонирования подпишите git clone и выполните:

- ▶ На git-хостингах предлагается выбор, клонировать по ssh или https. Для скачивания чего-то публичного проще использовать https, для регулярной разработки рекомендуется ssh, чтобы единожды залить на сервер свой публичный ключ и не вводить пароль при каждой команде. Итак, к адресу из команды клонирования подпишите git clone и выполните:
- ▶ `git clone https://gitlab.com/gitlab-org/gitlab.git`
- ▶ В результате у вас создается папка gitlab (можно задать другое название третьим аргументом git clone), которая будет соответствовать текущему состоянию проекта gitlab (может занять время, это большой проект, возможно, лучше клонировать что-то еще)

- ▶ На git-хостингах предлагается выбор, клонировать по ssh или https. Для скачивания чего-то публичного проще использовать https, для регулярной разработки рекомендуется ssh, чтобы единожды залить на сервер свой публичный ключ и не вводить пароль при каждой команде. Итак, к адресу из команды клонирования подпишите git clone и выполните:
- ▶ `git clone https://gitlab.com/gitlab-org/gitlab.git`
- ▶ В результате у вас создается папка gitlab (можно задать другое название третьим аргументом git clone), которая будет соответствовать текущему состоянию проекта gitlab (может занять время, это большой проект, возможно, лучше клонировать что-то еще)
- ▶ Перейдите в папку gitlab и выполните `git log`

- ▶ История разработки в git хранится в виде последовательности “коммитов”. Вот, например, последовательность коммитов по лекциям данного курса.

```
commit bce827c7fc752e1c0c2318a3ef41edf13d8f6d67 (HEAD -> main, origin/main, origin/HEAD)
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Fri Jul 25 13:38:29 2025 +0300
```

```
    final notes from last year, and students to keep
```

```
commit 2a98870ce7929479c7deec61648e512d86c1e444
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Tue Dec 24 11:39:42 2024 +0300
```

```
    notes on how to update lectures
```

```
commit d732353c1a8f064dd56f5a0679e1e41e51158df3
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Tue Dec 24 11:39:30 2024 +0300
```

```
    2024 lectures update
```

```
commit 2e8ecc0f4308a27074787cb9b83cfe265e3276a8
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Tue Dec 24 11:39:13 2024 +0300
```

```
    ignoring swp
```

- ▶ История разработки в git хранится в виде последовательности “коммитов”. Коммит это некое изменение в коде, в ряде его файлов, которое всегда можно посмотреть, какие изменения в код оно принесло. Последовательность коммитов образует ветку. На новом проекте она одна (master или main), в реальном большом проекте при совместной разработке их может быть много.

- ▶ История разработки в git хранится в виде последовательности “коммитов”. Коммит это некое изменение в коде, в ряде его файлов, которое всегда можно посмотреть, какие изменения в код оно принесло. Последовательность коммитов образует ветку. На новом проекте она одна (master или main), в реальном большом проекте при совместной разработке их может быть много.
- ▶ Всегда в рабочей папке вы можете посмотреть git status, то есть список того, что изменилось, дальше можно будет добавить все измененное (git add .) и сделать новый коммит (git commit -m “commit message”).
- ▶ Обратите внимание, что все эти действия локальные, они меняют состояние проекта в вашей папке и никак не влияют на то, что хранится на сервере.

Основы использования git

```
sander@sander-FX705DT:~/kurs$ git status
```

Текущая ветка: main

Эта ветка соответствует «origin/main».

Изменения, которые будут включены в коммит:

(используйте «git restore --staged <файл>...», чтобы убрать из индекса)

переименовано: lecture-notes -> lecture-notes-2024

Изменения, которые не в индексе для коммита:

(используйте «git add <файл>...», чтобы добавить файл в индекс)

(используйте «git restore <файл>...», чтобы отменить изменения в рабочем каталоге)

изменено: latex/1.tex

изменено: latex/2.tex

изменено: latex/3.tex

изменено: lecture-notes-2024

Неотслеживаемые файлы:

(используйте «git add <файл>...», чтобы добавить в то, что будет включено в коммит)

latex/images/gitlab.png

latex/images/kurs-commits.png

latex/images/risc-v.jpeg

plan-2025

- ▶ После того, как вы сделаете коммиты, вы увидите на git status, что локальная ветка обгоняет состояние на сервере

```
commit 3d0eddb071547b5ce9f1e8947e4ea3e82a896562 (HEAD -> main)
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Fri Aug 8 12:00:49 2025 +0300
```

updates on topics 1-3 with new images on risc-v and git

```
commit cb14712c8fd6d6a520bc3ea351408d39c6c20559
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Fri Aug 8 11:59:58 2025 +0300
```

plan for 2025

```
commit bce827c7fc752e1c0c2318a3ef41edf13d8f6d67 (origin/main, origin/HEAD)
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Fri Jul 25 13:38:29 2025 +0300
```

final notes from last year, and students to keep

```
commit 2a98870ce7929479c7deec61648e512d86c1e444
Author: Alexander Smirnov <asmirnov@srcc.msu.ru>
Date:   Tue Dec 24 11:39:42 2024 +0300
```

notes on how to update lectures

- ▶ Если после этого сделать команду `git push`, то состояние на сервере догонит локальное состояние

- ▶ Если после этого сделать команду `git push`, то состояние на сервере догонит локальное состояние
- ▶ `git pull` позволит получить обновления на другом компьютере.

- ▶ Если после этого сделать команду `git push`, то состояние на сервере догонит локальное состояние
- ▶ `git pull` позволит получить обновления на другом компьютере.
- ▶ Но какая может быть проблема при таких действиях

- ▶ Если после этого сделать команду `git push`, то состояние на сервере догонит локальное состояние
- ▶ `git pull` позволит получить обновления на другом компьютере.
- ▶ Но какая может быть проблема при таких действиях
- ▶ Совместная работа. Если кто-то сделал `push` в ветку, нельзя сделать в нее `push`, пока вы тоже не сделали `pull`, а если вы за это время сделали коммиты, их надо переносить

- ▶ Если после этого сделать команду `git push`, то состояние на сервере догонит локальное состояние
- ▶ `git pull` позволит получить обновления на другом компьютере.
- ▶ Но какая может быть проблема при таких действиях
- ▶ Совместная работа. Если кто-то сделал `push` в ветку, нельзя сделать в нее `push`, пока вы тоже не сделали `pull`, а если вы за это время сделали коммиты, их надо переносить
- ▶ Совместная работа требует правильной организации с ветвлением, когда создаются ветки под разные задачи, потом они по некоторым правилам сливаются в `main`. Есть разные подходы, можно читать про `gitflow`. Сайты типа `gitlab` позволяют при этом организовывать проверки, не позволяющие осуществить слияние пока, например, не прошли тесты.

Самое простое использование git для одного человека

- ▶ Заведите репозиторий на gitlab, склонируйте его
- ▶ После каждого изменения в коде делайте коммит и push
- ▶ Перед коммитом проверяйте git status и не делайте слепо git add . , если есть что-то ненужное
- ▶ Используйте файл .gitignore чтобы исключить ненужные файлы, создаваемые при работе, но не являющиеся частью кода
- ▶ Если работаете не на одном компьютере, то на каждом из них сначала pull, потом работа, commit и push. Это вам позволит избежать конфликтов.

Вопросы?



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ **Модули (с++20)**
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

- ▶ Курс на отказ от препроцессора в c++
- ▶ Улучшение времени сборки программ со сложной зависимостью

- ▶ Курс на отказ от препроцессора в c++
- ▶ Улучшение времени сборки программ со сложной зависимостью
- ▶ Давайте попробуем отказаться от `#include`

- ▶ Стандартный подход - пара файлов .h и .cpp

```
// main.cpp  
#include func.h  
int main(){  
    func();  
}
```

```
// func.h  
void func();
```

```
// func.cpp  
#include <iostream>  
#include func.h  
void func() {  
    std::cout << "hello , world!\n";  
}
```

- ▶ Если мы не включаем заголовочный файл, то нам как-то иначе нужно брать информацию о функциях, определенных в другом файле

- ▶ Если мы не включаем заголовочный файл, то нам как-то иначе нужно брать информацию о функциях, определенных в другом файле
- ▶ Новая инструкция `import`. Она не будет внедрять никакой `c++` код!

- ▶ Если мы не включаем заголовочный файл, то нам как-то иначе нужно брать информацию о функциях, определенных в другом файле
- ▶ Новая инструкция `import`. Она не будет внедрять никакой `c++` код!
- ▶ Но и из объектных файлов (если мы скомпилировали `func`) неудобно брать информацию о функциях

- ▶ Если мы не включаем заголовочный файл, то нам как-то иначе нужно брать информацию о функциях, определенных в другом файле
- ▶ Новая инструкция `import`. Она не будет внедрять никакой `c++` код!
- ▶ Но и из объектных файлов (если мы скомпилировали `func`) неудобно брать информацию о функциях
- ▶ Компилятором создаются принципиально новые файлы бинарного формата о скомпилированном модуле в директории `gcm.cache`

- ▶ Новый подход - файл `sxx` для модуля (так удобнее отличать от старого)

```
// main.cpp
import func;
int main(){
    func();
}
```

```
// func.cxx
module;
#include <iostream>
export module func;
export void func() {
    std::cout << "hello , world!\n";
}
```

► Сборка программы

```
g++ -c func.cxx -std=c++20 -fmodules-ts  
g++ -c -o main.o main.cpp -std=c++20  
      -fmodules-ts  
g++ -o main main.o func.o
```


► Сборка программы

```
g++ -c func.cxx -std=c++20 -fmodules-ts  
g++ -c -o main.o main.cpp -std=c++20  
      -fmodules-ts  
g++ -o main main.o func.o
```

- Нам нужен стандарт 20 и специальная опция для использования модулей
- После первой команды появится файл gcm.cache/func.gcm (здесь func - имя модуля, а не файла, но можно и использовать одинаковые)

- ▶ Сборка программы

```
g++ -c func.cxx -std=c++20 -fmodules-ts  
g++ -c -o main.o main.cpp -std=c++20  
      -fmodules-ts  
g++ -o main main.o func.o
```

- ▶ Нам нужен стандарт 20 и специальная опция для использования модулей
- ▶ После первой команды появится файл gcm.cache/func.gcm (здесь func - имя модуля, а не файла, но можно и использовать одинаковые)
- ▶ Поэтому важен порядок сборки - нужно сначала собрать func

► Напишем makefile

```
default: main
CXX=g++
OBJ=main.o func.o
CFLAGS=-std=c++20 -fmodules-ts
main: $(OBJ)
    $(CXX) -o $@ $^
%.o: %.cpp
    ${CXX} -c -o $@ $< ${CFLAGS}
%.o: %.cxx
    ${CXX} -c -o $@ $< ${CFLAGS}
gcm.cache/%.mod: %.cxx
    ${CXX} -c $^ ${CFLAGS}
main.o: main.cpp
main.o: gcm.cache/func.mod
func.o: func.cxx
```

- ▶ Если хочется, можно разделить файл модуля на два, с декларацией и имплементацией. Файлы будут называться по-разному, но описывать один и тот же модуль. Нет стандарта, как называть пары таких файлов, можно, например *func.cxx* и *func_impl.cxx*.
- ▶ Впрочем, необходимости в этом нет - ведь заголовочные файлы делались для минимизации включаемого в другой файл кода при компиляции, а здесь такого не происходит
- ▶ Компиляция того, что содержится в модуле, происходит в любом случае один раз!
- ▶ Так что, пора переводить все на модули?

► Поддержка gcc

<https://gcc.gnu.org/projects/cxx-status.html>

P1103R3	11 (requires -fmodules-ts) (No Private Module Fragment, Parser-level Global Module Entity Merging, Global Module Implications of extern "C/C++", or Partition-specific Definition Visibility)
P1766R1	No
P1811R0	11
P1703R1 (superseded by p1857)	11
P1874R1	11
P1979R0	11
P1779R3	11
P1857R3	11
P2115R0	11
P1815R2	No

- ▶ Поддержка модулей разными компиляторами: gcc-11 (partial), clang-8 (partial), msvc-19.0 (partial), msvc-19.28 (full), apple clang 10.0.1* (partial) (https://en.cppreference.com/w/cpp/compiler_support/20)

- ▶ Поддержка модулей разными компиляторами: gcc-11 (partial), clang-8 (partial), msvc-19.0 (partial), msvc-19.28 (full), apple clang 10.0.1* (partial) (https://en.cppreference.com/w/cpp/compiler_support/20)
- ▶ Но мало ведь толку от модулей, если они не используются в том коде, который вы используете! Что, например со стандартной библиотекой? Хочется `import std`

- ▶ Поддержка модулей разными компиляторами: gcc-11 (partial), clang-8 (partial), msvc-19.0 (partial), msvc-19.28 (full), apple clang 10.0.1* (partial) (https://en.cppreference.com/w/cpp/compiler_support/20)
- ▶ Но мало ведь толку от модулей, если они не используются в том коде, который вы используете! Что, например со стандартной библиотекой? Хочется `import std`
- ▶ Для этого нужен стандарт c++23, и поддержка на сегодня: clang-17 (partial), msvc-19.36 (full). (https://en.cppreference.com/w/cpp/compiler_support/23). Обещано в gcc-15 (добавление 2025)

Вопросы?



Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы **STL** (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

Стандарт c++17 принес много синтаксического сахара, удобные вещи для работы с шаблонами (`constexpr if`), но если мы вернемся к теме нашего курса, то основным нововведением кажутся параллельные алгоритмы STL

Стандарт c++17 принес много синтаксического сахара, удобные вещи для работы с шаблонами (`constexpr if`), но если мы вернемся к теме нашего курса, то основным нововведением кажутся параллельные алгоритмы STL

- ▶ Но сначала попробуем просто воспользоваться алгоритмами `std` для решения задачи суммирования вектора.

Стандарт c++17 принес много синтаксического сахара, удобные вещи для работы с шаблонами (`constexpr if`), но если мы вернемся к теме нашего курса, то основным нововведением кажутся параллельные алгоритмы STL

- ▶ Но сначала попробуем просто воспользоваться алгоритмами `std` для решения задачи суммирования вектора.
- ▶ У нас имелась функция суммирования вектора (или части вектора)

Стандарт c++17 принес много синтаксического сахара, удобные вещи для работы с шаблонами (constexpr if), но если мы вернемся к теме нашего курса, то основным нововведением кажутся параллельные алгоритмы STL

- У нас имелась функция суммирования вектора (или части вектора)

```
double sum_vector(std::vector<double>& a,  
    size_t start, size_t end) {  
    double res = 0.;  
    for (size_t i = start; i!=end; i++) {  
        res = res + a[i];  
    }  
    return res;  
}
```

Стандарт c++17 принес много синтаксического сахара, удобные вещи для работы с шаблонами (constexpr if), но если мы вернемся к теме нашего курса, то основным нововведением кажутся параллельные алгоритмы STL

- ▶ У нас имелась функция суммирования вектора (или части вектора)
- ▶ Перепишем же ее простым вызовом алгоритма stl

```
double sum_vector( std::vector<double>& a ,  
    size_t start , size_t end) {  
    return std::accumulate( a.begin() + start ,  
        a.begin() + end , 0.);  
}
```

- ▶ Код с `std::accumulate` позволяет не писать цикл, да, хорошо, но это все-таки просто небольшое удобство. А можно как-то параллелизовать этот код?

- ▶ Код с `std::accumulate` позволяет не писать цикл, да, хорошо, но это все-таки просто небольшое удобство. А можно как-то параллелизовать этот код?
- ▶ С `std::accumulate` нельзя, там старый алгоритм, не поддающийся параллелизации. Поэтому в c++17 появился новый алгоритм и новая функция `std::reduce`

- ▶ Код с `std::accumulate` позволяет не писать цикл, да, хорошо, но это все-таки просто небольшое удобство. А можно как-то параллелизовать этот код?
- ▶ С `std::accumulate` нельзя, там старый алгоритм, не поддающийся параллелизации. Поэтому в c++17 появился новый алгоритм и новая функция `std::reduce`

```
double sum_vector(std::vector<double>& a,  
    size_t start, size_t end) {  
    return std::reduce(a.begin() + start,  
        a.begin() + end, 0.);  
}
```

- ▶ Давайте замеряем время

- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms


- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms

- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms
- ▶ `std::reduce`: 130ms


- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms
- ▶ `std::reduce`: 130ms



- ▶ Если обратиться к статьям про алгоритмы `stl`, они все выдают, что `accumulate` последовательный



- ▶ Если обратиться к статьям про алгоритмы stl, они все выдают, что accumulate последовательный, а reduce собирает деревом



- ▶ Если обратиться к статьям про алгоритмы stl, они все выдают, что accumulate последовательный, а reduce собирает деревом, но в интернете врут, и, на самом деле, код reduce примерно такой:

```
double sum_vector(std::vector<double>& a,  
    size_t start, size_t end) {  
    double res = 0.;  
    for (size_t i = start; i!=end; i+=4) {  
        res = res + (a[i] + a[i + 1])  
            + (a[i + 2] + a[i + 3]);  
    }  
    return res;  
}
```

- ▶ Мы можем реализовать код от `std::reduce` сами и получить то же самое ускорение на одном ядре. Со всей сложностью современных процессоров практически невозможно увидеть “как текут байты”, но в целом логика ускорения в том, что у ядра процессора есть несколько блоков, выполняющих операции и ему удастся развести сложения и выполнять его параллельно на самом низком уровне.

- ▶ Мы можем реализовать код от `std::reduce` сами и получить то же самое ускорение на одном ядре. Со всей сложностью современных процессоров практически невозможно увидеть “как текут байты”, но в целом логика ускорения в том, что у ядра процессора есть несколько блоков, выполняющих операции и ему удастся развести сложения и выполнять его параллельно на самом низком уровне.
- ▶ Да, мы здесь исходим из ассоциативности сложения (что для машинной арифметики, вообще говоря, не так), но разбивая сами на блоки через `asus` мы тоже этим пользовались.

- ▶ Мы можем реализовать код от `std::reduce` сами и получить то же самое ускорение на одном ядре. Со всей сложностью современных процессоров практически невозможно увидеть “как текут байты”, но в целом логика ускорения в том, что у ядра процессора есть несколько блоков, выполняющих операции и ему удастся развести сложения и выполнять его параллельно на самом низком уровне.
- ▶ Да, мы здесь исходим из ассоциативности сложения (что для машинной арифметики, вообще говоря, не так), но разбивая сами на блоки через `asus` мы тоже этим пользовались.
- ▶ Но где же параллельность в `std::reduce`?

Задействуем параллелизацию для алгоритмов stl

```
#include <execution>
...
...
return std::reduce(std::execution::par,
    a.begin() + start,
    a.begin() + end, 0.);
```

- ▶ Если вы просто так попытаете это скомпилировать, то программа не скомпилируется. Необходимо добавить к опциям линковки `-ltbb`, причем поставить это после имени файла.

Задействуем параллелизацию для алгоритмов stl

```
#include <execution>
...
...
return std::reduce(std::execution::par,
    a.begin() + start,
    a.begin() + end, 0.);
```

- ▶ Если вы просто так попытаете это скомпилировать, то программа не скомпилируется. Необходимо добавить к опциям линковки `-ltbb`, причем поставить это после имени файла.
- ▶ Что за `tbb`?

TBB = Thread Building Blocks

- ▶ Thread building blocks — библиотека, изначально разработанная Intel (но работающая на различной архитектуре), реализующая различные параллельные алгоритмы
- ▶ Библиотекой можно пользоваться и отдельно, но начиная с c++17 она интегрирована для использования при помощи Parallel STL algorithms (этот путь прошли разные библиотеки, например, большие части boost)

TBB = Thread Building Blocks

- ▶ Thread building blocks — библиотека, изначально разработанная Intel (но работающая на различной архитектуре), реализующая различные параллельные алгоритмы
- ▶ Библиотекой можно пользоваться и отдельно, но начиная с c++17 она интегрирована для использования при помощи Parallel STL algorithms (этот путь прошли разные библиотеки, например, большие части boost)
- ▶ И все бы хорошо, но это отдельная библиотека, и даже в 2024 году на суперкомпьютере Ломоносов я так и не смог наладить полноценную компиляцию и работу программ с использованием TBB, а, значит, и Parallel STL Algorithms

- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms
- ▶ `std::reduce`: 130ms
- ▶ `std::reduce` with parallel execution: 82ms
- ▶ `async` with 4 cores: 103ms
- ▶ `async` with 8 cores: 87ms

- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms
- ▶ `std::reduce`: 130ms
- ▶ `std::reduce` with parallel execution: 82ms
- ▶ `async` with 4 cores: 103ms
- ▶ `async` with 8 cores: 87ms
- ▶ `async` with 4 cores and reduce code: 78ms

- ▶ Давайте замеряем время
- ▶ Одноядерная реализация с циклом: 222ms
- ▶ `std::accumulate`: 222ms
- ▶ `std::reduce`: 130ms
- ▶ `std::reduce` with parallel execution: 82ms
- ▶ `async` with 4 cores: 103ms
- ▶ `async` with 8 cores: 87ms
- ▶ `async` with 4 cores and reduce code: 78ms
- ▶ `async` with 8 cores and reduce code: 82ms

Async все-таки выиграл, если применить технику от `reduce`. Но 8 ядер ухудшают ситуацию. Так как проще писать?)))

Вопросы?





Многопоточное программирование в общей памяти с использованием стандартов C++11 и выше

- ▶ Введение, общая память и библиотеки
- ▶ Использование потоков, передача в них параметров и возврат значений (с++11)
- ▶ Параллельная работа в общей памяти, механизмы обеспечения синхронизации (с++11)
- ▶ `std::async` и суммирование вектора (с++11)
- ▶ Make и Makefile. Основы использования git.
- ▶ Модули (с++20)
- ▶ Параллельные алгоритмы STL (с++17)
- ▶ Введение в корутины (с++20 и немного с++23)

Корутины, они же сопрограммы

- ▶ Понятие корутин давно существует в других языках. Если “на пальцах”, то корутина — это функция, чье выполнение можно приостановить при помощи промежуточного “return” или “await”, а потом возобновить из другой функции.

Корутины, они же сопрограммы



Корутины, они же сопрограммы

- ▶ Понятие корутин давно существует в других языках. Если “на пальцах”, то корутина — это функция, чье выполнение можно приостановить при помощи промежуточного “return” или “await”, а потом возобновить из другой функции.
- ▶ Как проще всего реализовать функциональность такой приостановки, используя описанное выше?

Корутины, они же сопрограммы

- ▶ Понятие корутин давно существует в других языках. Если “на пальцах”, то корутина — это функция, чье выполнение можно приостановить при помощи промежуточного “return” или “await”, а потом возобновить из другой функции.
- ▶ Как проще всего реализовать функциональность такой приостановки, используя описанное выше?
- ▶ Конечно, отдельным потоком и mutex/condition_variable. А чем это может нас не устраивать?

Корутины, они же сопрограммы

- ▶ Понятие корутин давно существует в других языках. Если “на пальцах”, то корутина — это функция, чье выполнение можно приостановить при помощи промежуточного “return” или “await”, а потом возобновить из другой функции.
- ▶ Как проще всего реализовать функциональность такой приостановки, используя описанное выше?
- ▶ Конечно, отдельным потоком и `mutex/condition_variable`. А чем это может нас не устраивать?
- ▶ Основная причина — вовсе не простота синтаксиса, а стоимость переключения контекста

Корутины, они же сопрограммы

- ▶ Понятие корутин давно существует в других языках. Если “на пальцах”, то корутина — это функция, чье выполнение можно приостановить при помощи промежуточного “return” или “await”, а потом возобновить из другой функции.
- ▶ Как проще всего реализовать функциональность такой приостановки, используя описанное выше?
- ▶ Конечно, отдельным потоком и mutex/condition_variable. А чем это может нас не устраивать?
- ▶ Основная причина — вовсе не простота синтаксиса, а стоимость переключения контекста
- ▶ Корутины это не про параллелизацию, а про асинхронность!

Корутины

itshare.com

Operation Cost in CPU Cycles

10^0

10^1

10^2

10^3

10^4

10^5

10^6

"Simple" register-register op (ADD, OR, etc.)

<1

Memory write

<1

Bypass delay: switch between integer and floating-point units

0-2

"Right" branch of "if"

1-2

Floating-point/vector addition

1-3

Multiplication (integer/float/vector)

1-7

Return error and check

1-7

L1 read

3-4

TLB miss

7-21

L2 read

10-12

"Wrong" branch of "if" (branch misprediction)

10-20

Floating-point division

10-40

128-bit vector division

10-70

Atomics/CAS

15-30

C function direct call

15-30

Integer division

15-40

C function indirect call

20-60

C++ virtual function call

30-60

L3 read

30-70

Main RAM read

100-150

NUMA: different-socket atomics/CAS (guesstimate)

100-320

NUMA: different-socket L3 read

100-320

Allocation+deallocation pair (small objects)

200-500

NUMA: different-socket main RAM read

200-500

Kernel call

1000-1500

Thread context switch (direct costs)

2000

C++ Exception thrown+caught

5000-10000

Thread context switch (total costs, including cache invalidation)

10000 - 1 million

Корутины, они же сопрограммы

- ▶ Итак, корутина это приостанавливаемая функция, выполняемая в том же потоке, что и вызывающая ее функция, что дает легковесность переключения контекста.

Корутины, они же сопрограммы

- ▶ Итак, корутина это приостанавливаемая функция, выполняемая в том же потоке, что и вызывающая ее функция, что дает легковесность переключения контекста.
- ▶ Один из типов корутин — стековые корутины, они же зеленые потоки, волокна и горутины. Они отличаются наличием своего стека вызовов (call stack).

Корутины, они же сопрограммы

- ▶ Итак, корутина это приостанавливаемая функция, выполняемая в том же потоке, что и вызывающая ее функция, что дает легковесность переключения контекста.
- ▶ Один из типов корутин — стековые корутины, они же зеленые потоки, волокна и горутины. Они отличаются наличием своего стека вызовов (call stack).
- ▶ Существуют библиотеки, реализующие стековые корутины, как на чистом си, так и под с++ (например, в boost). Однако выделение отдельного стека требует ресурсы, а переключение все равно достаточно дорогое, поэтому в с++ они так и не обрели популярность.

Бесстековые корутины

- ▶ Стандарт c++20 приносит бесстековые корутины, под локальные переменные которых выделяется память в куче, но при этом “вызов” или “продолжение” корутины происходят в обычном стеке, соответственно, дальнейшие вызовы функций из бесстековой корутины производятся на стеке родителя. Что означает, в частности, что приостановка возможна только из основной функции корутины. Впрочем, с этим ограничением можно смириться в обмен на производительность.

Бесстековые корутины

- ▶ Стандарт c++20 приносит бесстековые корутины, под локальные переменные которых выделяется память в куче, но при этом “вызов” или “продолжение” корутины происходят в обычном стеке, соответственно, дальнейшие вызовы функций из бесстековой корутины производятся на стеке родителя. Что означает, в частности, что приостановка возможна только из основной функции корутины. Впрочем, с этим ограничением можно смириться в обмен на производительность.
- ▶ В связи с такой структурой реализовать такую корутину в виде библиотеки невозможно, поэтому и ждали, когда оно появится в стандарте.

Бесстековые корутины

- ▶ Стандарт c++20 приносит бесстековые корутины, под локальные переменные которых выделяется память в куче, но при этом “вызов” или “продолжение” корутины происходят в обычном стеке, соответственно, дальнейшие вызовы функций из бесстековой корутины производятся на стеке родителя. Что означает, в частности, что приостановка возможна только из основной функции корутины. Впрочем, с этим ограничением можно смириться в обмен на производительность.
- ▶ В связи с такой структурой реализовать такую корутину в виде библиотеки невозможно, поэтому и ждали, когда оно появится в стандарте.
- ▶ К сожалению, воспользоваться корутинами достаточно сложно, и код вовсе не становится лаконичным.

Код, который хотелось бы видеть

```
generator generate(size_t start, size_t end) {  
    for (auto i = start; i < end; ++i) {  
        co_yield i;  
    }  
}  
  
int main() {  
    for (auto value: generate(0, 10)) {  
        std::cout << value << std::endl;  
    }  
    return 0;  
}
```

Код, который хотелось бы видеть

```
generator generate(size_t start, size_t end) {  
    for (auto i = start; i < end; ++i) {  
        co_yield i;  
    }  
}  
  
int main() {  
    for (auto value: generate(0, 10)) {  
        std::cout << value << std::endl;  
    }  
    return 0;  
}
```

Однако, приходится написать очень много кода

Мы должны описать класс `generator`

- ▶ Он должен внутри себя иметь класс `iterator`, содержащий операторы `++`, `*` и `!=`
- ▶ Также класс `generator` должен иметь методы `begin()` и `end()`, возвращающие `iterator`

Мы должны описать класс `generator`

- ▶ Он должен внутри себя иметь класс `iterator`, содержащий операторы `++`, `*` и `!=`
- ▶ Также класс `generator` должен иметь методы `begin()` и `end()`, возвращающие `iterator`
- ▶ Но, главное, чтобы функция могла вызвать `co_yield` и все это работало, он должен внутри себя содержать структуру `promise_type` с определенным набором свойств. Давайте попробуем все это реализовать

Мы должны описать класс `generator`

- ▶ Он должен внутри себя иметь класс `iterator`, содержащий операторы `++`, `*` и `!=`
- ▶ Также класс `generator` должен иметь методы `begin()` и `end()`, возвращающие `iterator`
- ▶ Но, главное, чтобы функция могла вызвать `co_yield` и все это работало, он должен внутри себя содержать структуру `promise_type` с определенным набором свойств. Давайте попробуем все это реализовать
- ▶ Если вложенный тип это `promise`, то по аналогии обертывающий тип `generator` это `future` (не в смысле прямого совпадения типов с описанным выше)

`get_return_object` — Создает экземпляр типа `generator` (ведь в функции `generate` нет `return`!). Она вызовется при “вызове” корутины и возврате изначального значения.

```
class generator {  
public :  
    struct promise_type {  
        using suspend_never=std::suspend_never ;  
        using suspend_always=std::suspend_always ;  
        using handle =  
        std::coroutine_handle<promise_type>;  
        size_t value ;  
        auto get_return_object() noexcept {  
            return generator{  
                handle::from_promise(*this)  
            };  
        }  
    }
```

```
suspend_never initial_suspend()
    noexcept { return {}; }
suspend_always final_suspend()
    noexcept { return {}; }
void return_void() noexcept {}
void unhandled_exception()
    { std::terminate(); }
suspend_always yield_value(size_t v)
    noexcept {
        value = v;
        return {};
    }
};
```

- ▶ `initial_suspend` возвращаемым значением определяет, что корутина сразу начнет работу после создания и дойдет до первого `co_yield`.

```
suspend_never initial_suspend()
    noexcept { return {}; }
suspend_always final_suspend()
    noexcept { return {}; }
void return_void() noexcept {}
void unhandled_exception()
    { std::terminate(); }
suspend_always yield_value(size_t v)
    noexcept {
        value = v;
        return {};
    }
};
```

- ▶ `final_suspend` возвращаемым значением говорит не уничтожать корутину после того, как она дошла до конца выполнения.

```
suspend_never initial_suspend()
    noexcept { return {}; }
suspend_always final_suspend()
    noexcept { return {}; }
void return_void() noexcept {}
void unhandled_exception()
    { std::terminate(); }
suspend_always yield_value(size_t v)
    noexcept {
        value = v;
        return {};
    }
};
```

- ▶ `return_void` ничего не делает, поскольку мы не используем `co_return`.

```
suspend_never initial_suspend()
    noexcept { return {}; }
suspend_always final_suspend()
    noexcept { return {}; }
void return_void() noexcept {}
void unhandled_exception()
    { std::terminate(); }
suspend_always yield_value(size_t v)
    noexcept {
        value = v;
        return {};
    }
};
```

- ▶ Также мы не обрабатываем исключения

```
suspend_never initial_suspend()
    noexcept { return {}; }
suspend_always final_suspend()
    noexcept { return {}; }
void return_void() noexcept {}
void unhandled_exception()
    { std::terminate(); }
suspend_always yield_value(size_t v)
    noexcept {
        value = v;
        return {};
    }
};
```

- ▶ `yield_value` это обработка `co_yield` с сохранением значение в входе в ожидание

```
private:
    promise_type::handle m_coro;
public:
    ~generator() noexcept { m_coro.destroy(); }
    class iterator {
    private:
        generator *m_self;
    public:
        bool operator != (iterator second) const {
            return m_self != second.m_self;
        }
        size_t operator *() {
            return m_self->m_coro.promise().value;
        }
    }
```

► m_coro — “указатель на промис”

private :

```
promise_type :: handle m_coro;
```

public :

```
~generator() noexcept { m_coro.destroy(); }
```

```
class iterator {
```

private :

```
generator *m_self;
```

public :

```
bool operator != (iterator second) const {
```

```
    return m_self != second.m_self;
```

```
}
```

```
size_t operator*() {
```

```
    return m_self->m_coro.promise().value;
```

```
}
```

- ▶ Деструктор генератора вызывает разрушение фрейма корутины (мы это приостановили в `final_suspend`)


```
private:
```

```
    promise_type::handle m_coro;
```

```
public:
```

```
~generator() noexcept { m_coro.destroy(); }
```

```
    class iterator {
```

```
    private:
```

```
        generator *m_self;
```

```
    public:
```

```
        bool operator != (iterator second) const {
```

```
            return m_self != second.m_self;
```

```
        }
```

```
        size_t operator *() {
```

```
            return m_self->m_coro.promise().value;
```

```
        }
```

- ▶ Вложенный класс итератора содержит указатель на сам генератор

```
private:
    promise_type::handle m_coro;
public:
    ~generator() noexcept { m_coro.destroy(); }
    class iterator {
    private:
        generator *m_self;
    public:
        bool operator != (iterator second) const {
            return m_self != second.m_self;
        }
        size_t operator *() {
            return m_self->m_coro.promise().value;
        }
    }
```

- Неравенство итератора для завершения работы цикла

```
private:
```

```
    promise_type::handle m_coro;
```

```
public:
```

```
~generator() noexcept { m_coro.destroy(); }
```

```
    class iterator {
```

```
    private:
```

```
        generator *m_self;
```

```
    public:
```

```
        bool operator != (iterator second) const {
```

```
            return m_self != second.m_self;
```

```
        }
```

```
        size_t operator *() {
```

```
            return m_self->m_coro.promise().value;
```

```
        }
```

- ▶ Оператор взятия значения, как и положено, возвращает сохраненное значение из промиса

```
iterator & operator++() {  
    m_self->m_coro.resume();  
    if (m_self->m_coro.done()) {  
        m_self = nullptr;  
    }  
    return *this;  
}  
  
private:  
    iterator(generator *self): m_self{self} {}  
    friend class generator;  
};
```

- ▶ Оператор инкремента проверяет возобновляет выполнение корутины - генератора, далее проверяет, завершилась ли корутина, и если да, возвращает nullptr, что потребуется для сравнения с end() — увидим на следующем слайде

```
iterator begin() { return iterator{  
    m_coro.done() ? nullptr : this  
}; }  
iterator end() {return iterator{nullptr};}  
private :  
    explicit generator  
        (promise_type::handle coro)  
        noexcept: m_coro{coro} {}  
};
```

- ▶ Метод `begin()` у итератора проверяет не закончились ли числа (дали пустой интервал), и, если нет, возвращает указатель на класс итератора.

```
iterator begin() { return iterator{  
    m_coro.done() ? nullptr : this  
}; }  
iterator end() {return iterator{nullptr};}  
private:  
    explicit generator  
        (promise_type::handle coro)  
        noexcept: m_coro{coro} {}  
};
```

- ▶ Метод end() всегда возвращает нулевой итератор. Они станут равны только когда корутина завершила работу

```
iterator begin() { return iterator{  
    m_coro.done() ? nullptr : this  
}; }  
iterator end() {return iterator{nullptr};}  
private :  
    explicit generator  
        (promise_type::handle coro)  
        noexcept: m_coro{coro} {}  
};
```

- ▶ Конструктор генератора. Он должен быть именно такой (с сохранением ссылки на корутину), он вызовется из `get_return_object`

Генератор в c++23

- ▶ c++23 представляет первую корутину, включенную в библиотеку (не надо писать свои `promise` и `future`).

Генератор в c++23

- ▶ c++23 представляет первую корутину, включенную в библиотеку (не надо писать свои `promise` и `future`).

```
std::generator<int> fib () {  
    co_yield 0;  
    auto a = 0;  
    auto b = 1;  
    for (auto n : std::views::iota(0)) {  
        auto next = a + b;  
        a = b;  
        b = next;  
        co_yield next;  
    }  
}
```

Генератор в c++23

```
int main() {  
    for (auto f : fib() |  
        std::views::take(10)) {  
        std::cout << f << " ";  
    }  
}
```

- ▶ Здесь задействована библиотека `ranges` из c++20 и ей определенная перегрузка оператора побитового или, работающая похоже на “трубопровод” из командной строки.

Генератор в c++23

```
int main() {  
    for (auto f : fib() |  
        std::views::take(10)) {  
        std::cout << f << " ";  
    }  
}
```

- ▶ Здесь задействована библиотека `ranges` из c++20 и ей определенная перегрузка оператора побитового или, работающая похоже на “трубопровод” из командной строки.
- ▶ Все это выглядит куда более красиво, однако это пока единственная корутина из стандартной библиотеки, а, кроме того, на текущий момент из компиляторов поддержка заявлена только в g++ 14.

Вопросы?



Внимание! Задание!

1. Найти максимум в массиве
2. Найти количество положительных элементов в массиве
3. Найти сумму массива (да, это было на лекциях, но реализуйте в коде)
4. Найти первое число, превышающее предварительно заданное

Вы должны написать программу, которая делает одно из написанного выше. Чтобы определить, что, возьмите остаток от деления вашего номера на 4 и прибавьте 1.

В виде формулы это $(number \% 4) + 1$

Внимание! Задание!

1. реализовать при помощи априорного разделения, использовать `packaged_task`
2. реализовать при помощи `atomic` (общий счетчик)
3. реализовать при помощи `mutex` (без `condition_variable`), возвращать из потоков значение через `future/promise`
4. реализовать при помощи `mutex + condition_variable`
5. реализовать при помощи `parallel stl`

Вы должны использовать один из методов параллелизации выше.

Чтобы определить, возьмите целое частное от деления вашего номера на 4, затем остаток от деления на 5 и прибавьте 1.

В виде формулы это $((number/4)\%5) + 1$

Внимание! Задание!

Варианты чисел в массиве:

1. int (32-bit)
2. float
3. long int / long long int (64-bit)
4. double

Чтобы определить ваш вариант, возьмите целое частное от деления вашего номера на 20 и прибавьте 1

В виде формулы это $(number/20) + 1$

Внимание! Задание!

- ▶ Обратите внимание! Вы можете разрабатывать в какой-то среде, но у проверяющего (меня), может не быть этой среды. У меня вообще может быть другая операционная система. Не стоит присылать файлы проекта и тому подобное

Внимание! Задание!

- ▶ Обратите внимание! Вы можете разрабатывать в какой-то среде, но у проверяющего (меня), может не быть этой среды. У меня вообще может быть другая операционная система. Не стоит присылать файлы проекта и тому подобное
- ▶ В то же время, мне нужны инструкции для сборки, чтобы не заниматься догадками, как правильно собирать программу. Кроме того, это сейчас ваша программа может состоять из одного файла, но представьте, будто вы сдаете полноценный проект, который может быть и многокомпонентным.

Внимание! Задание!

- ▶ Обратите внимание! Вы можете разрабатывать в какой-то среде, но у проверяющего (меня), может не быть этой среды. У меня вообще может быть другая операционная система. Не стоит присылать файлы проекта и тому подобное
- ▶ В то же время, мне нужны инструкции для сборки, чтобы не заниматься догадками, как правильно собирать программу. Кроме того, это сейчас ваша программа может состоять из одного файла, но представьте, будто вы сдаете полноценный проект, который может быть и многокомпонентным.
- ▶ Ваша программа - консольная, а значит для ее сборки и запуска не нужна никакая среда. Я буду проверять их, компилируя и запуская в командной строке.

Внимание! Задание!

- ▶ Обратите внимание! Вы можете разрабатывать в какой-то среде, но у проверяющего (меня), может не быть этой среды. У меня вообще может быть другая операционная система. Не стоит присылать файлы проекта и тому подобное
- ▶ В то же время, мне нужны инструкции для сборки, чтобы не заниматься догадками, как правильно собирать программу. Кроме того, это сейчас ваша программа может состоять из одного файла, но представьте, будто вы сдаете полноценный проект, который может быть и многокомпонентным.
- ▶ Ваша программа - консольная, а значит для ее сборки и запуска не нужна никакая среда. Я буду проверять их, компилируя и запуская в командной строке.
- ▶ Минимум - должна поставляться команда сборки. В идеале - организация сборки, например makefile

Внимание! Задание!

Рекомендованная сборка:

- ▶ Makefile (или что-то иное типа cmake)

Внимание! Задание!

Рекомендованная сборка:

- ▶ Makefile (или что-то иное типа cmake)
- ▶ Сборка с -D, чтобы в зависимости от параметров была параллельная или линейная версия или количество ядер

Внимание! Задание!

Рекомендованная сборка:

- ▶ Makefile (или что-то иное типа cmake)
- ▶ Сборка с -D, чтобы в зависимости от параметров была параллельная или линейная версия или количество ядер
- ▶ Подача единым архивом (или заведите репозиторий)

Внимание! Задание!

Рекомендованная сборка:

- ▶ Makefile (или что-то иное типа cmake)
- ▶ Сборка с -D, чтобы в зависимости от параметров была параллельная или линейная версия или количество ядер
- ▶ Подача единым архивом (или заведите репозиторий)
- ▶ Сопровождающий текст с комментариями, как оно работает

Внимание! Задание!

Рекомендованная сборка:

- ▶ Makefile (или что-то иное типа cmake)
- ▶ Сборка с -D, чтобы в зависимости от параметров была параллельная или линейная версия или количество ядер
- ▶ Подача единым архивом (или заведите репозиторий)
- ▶ Сопровождающий текст с комментариями, как оно работает
- ▶ Не забудьте вывести ваш номер и написать, какую задачу вы решали!

Вопросы?

